

UNIVERSIDAD NACIONAL DE SAN ANTONIO ABAD DEL CUSCO

**FACULTAD DE INGENIERÍA ELÉCTRICA, ELECTRÓNICA, INFORMÁTICA Y
MECÁNICA**



ESCUELA PROFESIONAL DE INGENIERÍA INFORMÁTICA Y DE SISTEMAS

PLAN DE TESIS

**SISTEMA AUTOMATIZADO DE TRANSCRIPCIÓN DE
AUDIENCIAS JUDICIALES
EMPLEANDO INTELIGENCIA ARTIFICIAL EN EL
DISTRITO JUDICIAL DE CUSCO**

PRESENTADO POR

Br. JESÚS ABRAHAM UCHIRI QUISPE
Código: 080227

Br. CARLA PALOMA CUETO SÁNCHEZ
Código: 120008

Tesis para optar al título profesional de:
INGENIERO INFORMÁTICO Y DE SISTEMAS

ASESOR

Mg. JOSÉ MAURO PILLCO QUISPE

CUSCO – PERÚ

2026

Índice

Lista de Tablas	5
1 Introducción	1
2 Justificación de la investigación	1
2.1 Por su Conveniencia	1
2.2 Por su Relevancia	2
2.3 Por sus Implicancias Prácticas	3
2.4 Por su Valor Teórico	3
2.5 Por su Valor Metodológico	3
3 Planteamiento y formulación del problema de investigación	4
3.1 Formulación de la Pregunta de Investigación	6
3.1.1 Problema General	6
3.1.2 Problemas Específicos	6
4 Alcances y limitaciones	6
4.1 Delimitación Temporal	6
4.2 Delimitación Espacial	7
5 Objetivos	7
5.1 Objetivo General	7
5.2 Objetivos Específicos	7
6 Reglamentación y transcripción de audiencias judiciales en el Perú	8
6.1 Marco legal que ordena el registro de las audiencias	8
6.2 Evolución normativa de las audiencias virtuales	9
6.3 Obligaciones del especialista judicial de audiencia	9
6.4 Confidencialidad y protección de datos en el registro judicial	10
6.5 Normas sobre el uso de firmas digitales en actas judiciales	10
7 Antecedentes (estado del arte)	11
7.1 Antecedentes a Nivel Internacional	11
7.1.1 Garneau y Bolduc (2024)	11

7.1.2	Harrington (2023)	12
7.1.3	Loakes (2024)	12
7.1.4	Saadany, Orasan, Walker y Breslin (2025)	13
7.1.5	Lyra, Barbosa, Salazar, Argôlo y De Souza (2024)	14
7.2	Antecedentes a Nivel Nacional	14
7.2.1	Vera (2021)	14
7.2.2	Larrea (2024)	15
7.2.3	Poder Judicial del Perú (2023)	15
7.3	Antecedentes a Nivel Local	16
8	Marco teórico	16
8.1	Reglamentación y proceso de audiencia judicial en el Perú	16
8.1.1	Sistemas automatizados en entornos judiciales	16
8.1.2	Valor legal de las actas de audiencia	17
8.1.3	Aspectos de redacción y estilo en actas	17
8.2	Inteligencia Artificial y reconocimiento automático del habla	17
8.2.1	Fundamentos del reconocimiento automático del habla	17
8.2.2	Arquitectura Transformer en reconocimiento del habla	18
8.2.3	Función de pérdida CTC para transcripción en tiempo real	18
8.2.4	Diarización de hablantes	19
8.2.5	Indicador de confianza por palabra	19
8.3	Servicio de reconocimiento automático del habla: Deepgram Nova-3	20
8.3.1	Descripción del servicio y evolución	20
8.3.2	Parámetros de configuración para el contexto judicial	20
8.3.3	Transcripción en tiempo real durante audiencias en vivo	21
8.3.4	Transcripción diferida de archivos pregrabados	21
8.4	Modelo de lenguaje para mejoramiento de texto: Claude Sonnet	22
8.4.1	Descripción del modelo y su función en el sistema	22
8.4.2	Arquitectura de generación autoregresiva	23
8.4.3	Control de temperatura en el mejoramiento de texto	23
8.5	Métricas y parámetros de evaluación	24
8.5.1	Word Error Rate y Character Error Rate	24
8.5.2	Métricas de latencia y tiempo de procesamiento	24

8.5.3	Mean Opinion Score	25
8.5.4	Validación estadística	25
8.6	Desarrollo del sistema propuesto	25
8.6.1	Descripción general	25
8.6.2	Arquitectura de software	26
8.6.3	Stack tecnológico	27
8.6.4	Corpus lingüístico judicial	27
8.6.5	Diccionario jurídico local	28
8.6.6	Modelo de datos	28
8.6.7	Seguridad del sistema	28
8.7	Marco Conceptual	29
8.7.1	Inteligencia Artificial	29
8.7.2	Reconocimiento Automático del Habla	29
8.7.3	Transcripción Judicial	29
8.7.4	Celeridad Procesal	29
8.7.5	WebSocket	30
8.7.6	Word Error Rate	30
8.7.7	FastAPI	30
8.7.8	PostgreSQL	30
8.7.9	Docker	31
9	Metodología de la investigación	31
9.1	Metodología de Investigación	31
9.2	Tipo y Alcance de Investigación	31
9.2.1	Tipo de Investigación	31
9.2.2	Método de Investigación	32
9.2.3	Diseño de Investigación	32
9.2.4	Enfoque de Investigación	32
9.3	Corpus y Unidad de Análisis	32
9.4	Población y Muestra	33
9.5	Técnicas e Instrumentos de Recolección de Datos	33
10	Cronograma de actividades	33

11 Presupuesto	34
11.1 Recursos Humanos	34
11.2 Servicios de Inteligencia Artificial	35
11.3 Infraestructura Tecnológica	35
11.4 Materiales y Otros Gastos	35
11.5 Resumen General del Presupuesto	36
Referencias	36

Índice de cuadros

1	Parámetros de configuración del servicio de reconocimiento del habla en modo de flujo continuo	21
2	Comparación entre modalidades de transcripción del sistema	22
3	Stack tecnológico del sistema propuesto	27
4	Entidades principales del modelo de datos	28
5	Cronograma de actividades (3 meses)	34
6	Presupuesto de recursos humanos	34
7	Presupuesto de servicios de inteligencia artificial	35
8	Presupuesto de infraestructura tecnológica	35
9	Presupuesto de materiales y otros gastos	35
10	Resumen general del presupuesto del proyecto	36

1 Introducción

La correcta documentación de las actuaciones procesales es un pilar fundamental para garantizar la transparencia y la seguridad jurídica. Sin embargo, en diversas dependencias del Poder Judicial, particularmente en el Distrito Judicial de Cusco, gran parte del registro de audiencias se sigue elaborando mediante transcripción manual. Esta tarea recae directamente sobre los secretarios y especialistas de audiencia, quienes se enfrentan no solo a la velocidad del dictado presencial y virtual, sino también al desgaste propio de jornadas extensas. Como resultado, la emisión rápida y exacta de las actas se ve comprometida.

Con la creciente digitalización impulsada tras la reciente pandemia, el número de audiencias virtuales ha superado las predicciones, saturando la capacidad de respuesta del personal administrativo. Ante este escenario, el uso de herramientas tecnológicas basadas en inteligencia artificial, específicamente el reconocimiento automático del habla acompañado del procesamiento de lenguaje natural, surge como una alternativa técnica viable para agilizar las labores judiciales rutinarias. Los avances en modelos de transcripción a gran escala como Whisper (Radford et al., 2023) y en modelos de lenguaje de gran escala como Claude Sonnet han demostrado que la integración de ambas tecnologías puede producir documentos estructurados con alta fidelidad semántica en contextos especializados.

El presente plan de tesis expone la formulación de un proyecto cuyo fin es desarrollar y validar un sistema automatizado de transcripción adaptado a la realidad de las salas de audiencia locales. A lo largo de este documento se presenta la justificación del estudio, se plantean formalmente los objetivos de investigación y se detalla el marco analítico y normativo. Finalmente, se delinea la ruta metodológica, los recursos necesarios y el cronograma trazado para lograr la construcción exitosa del sistema como aporte tecnológico directo a la administración de justicia cusqueña.

2 Justificación de la investigación

2.1 Por su Conveniencia

El presente estudio se justifica por la necesidad de mejorar el tiempo y la precisión en el registro de las actas de audiencias del Distrito Judicial de Cusco. La transcripción ma-

nual ha demostrado ser lenta, propensa a errores y con una carga administrativa excesiva que afecta directamente la continuidad procesal y la calidad del servicio de justicia. Implementar un sistema automatizado basado en reconocimiento automático del habla resulta conveniente porque permitirá superar estas limitaciones y alinear el Poder Judicial con tendencias globales de digitalización. Lyra et al. (2024) desarrollaron en Brasil un sistema de transcripción automática para audiencias judiciales que redujo de manera significativa el tiempo de elaboración de actas, evidenciando la viabilidad de esta tecnología en el contexto jurídico latinoamericano.

Desde la perspectiva metodológica, la conveniencia de este trabajo radica también en su factibilidad: hace uso de herramientas de reconocimiento automático del habla ya existentes y consolidadas, no requiere entrenar modelos de inteligencia artificial desde cero y puede desplegarse sobre infraestructura disponible. Esto lo convierte en una solución práctica, replicable y pertinente para las necesidades institucionales concretas del Distrito Judicial de Cusco.

2.2 Por su Relevancia

La relevancia de la presente investigación reside en el impacto directo que tendrá sobre la calidad y precisión de las transcripciones de audiencias, aspecto vital para garantizar el derecho al debido proceso. En América Latina y en el Perú son escasos los estudios empíricos que evalúen la eficacia de los sistemas de reconocimiento automático del habla en contextos judiciales, lo que evidencia un vacío académico que esta investigación busca abordar. Garneau y Bolduc (2024) demostraron que ninguno de los sistemas comerciales analizados alcanza la precisión requerida para prescindir de supervisión humana en entornos judiciales, lo que subraya la necesidad de evaluar estas tecnologías en contextos específicos como el judicial peruano con sus particularidades lingüísticas y operativas.

La relevancia se fortalece además al considerar que este trabajo contribuye a resolver una problemática real con implicancias sociales y jurídicas directas: al mejorar la calidad y celeridad de las actas, se refuerza la confianza ciudadana en el sistema de justicia y se reduce la sobrecarga del personal judicial.

2.3 Por sus Implicancias Prácticas

Las implicancias prácticas de esta investigación son múltiples. A corto plazo, permitirá obtener actas judiciales con mayor rapidez y con un menor número de errores, reduciendo la sobrecarga del personal judicial. A mediano y largo plazo, el modelo puede replicarse en otros distritos judiciales del país, generando un estándar tecnológico de justicia digital. Saadany et al. (2025) desarrollaron para el Tribunal Supremo del Reino Unido un sistema que combina reconocimiento automático del habla adaptado al dominio legal con incrustaciones semánticas GPT, logrando reducir la tasa de error en un 9 % respecto a los motores genéricos, lo que abre la posibilidad de integrar en el futuro componentes de análisis semántico y búsqueda automática de jurisprudencia.

Estas implicancias se justifican por el aporte a la transformación digital del Poder Judicial y por el beneficio directo que otorgan a jueces, secretarios, fiscales y ciudadanos que requieren procesos más céleres y confiables.

2.4 Por su Valor Teórico

En el plano teórico, este estudio aporta al desarrollo del conocimiento aplicado al campo de la ingeniería informática y al derecho, al demostrar cómo la integración de herramientas de inteligencia artificial puede incidir en la calidad de las transcripciones judiciales. Si bien existen investigaciones en tribunales europeos y anglosajones (Saadany et al., 2025; Harrington, 2023), son escasos los estudios que exploran su aplicación en el ámbito latinoamericano y particularmente en el Perú. Esto convierte a la investigación en un referente pionero en su contexto.

El valor teórico radica asimismo en vincular la innovación tecnológica con la garantía de derechos fundamentales: al mejorar la fidelidad de los registros procesales mediante herramientas de inteligencia artificial, se fortalece el principio de publicidad y el derecho al debido proceso.

2.5 Por su Valor Metodológico

La investigación tiene una utilidad metodológica relevante, pues adopta un enfoque de evaluación tecnológica basado en métricas estándar del campo del reconocimiento auto-

mático del habla (WER, CER, RTF, MOS) y construye un corpus lingüístico judicial a partir de grabaciones reales del Distrito Judicial de Cusco. Este corpus y la metodología de evaluación pueden ser reutilizados en estudios posteriores, sirviendo como referencia para futuras investigaciones en contextos judiciales o administrativos del ámbito peruano.

La utilidad metodológica se justifica también porque permite garantizar la transparencia y reproducibilidad de los resultados, asegurando que la innovación propuesta pueda validarse y sostenerse en investigaciones futuras.

3 Planteamiento y formulación del problema de investigación

En el Distrito Judicial de Cusco, el registro de las audiencias judiciales, tanto presenciales como virtuales, se realiza mediante transcripción manual a cargo de secretarios y especialistas de audiencia. Esta práctica genera retrasos en la elaboración de actas, acumula errores por la fatiga y la velocidad del dictado, y representa una carga administrativa importante sobre el personal judicial. Como resultado, se pone en riesgo la calidad y confiabilidad de los registros procesales, problema que se ha agravado con el creciente uso de audiencias virtuales desde la pandemia de COVID-19.

Las causas de esta problemática son varias. Primero, persiste una fuerte dependencia de métodos manuales tradicionales que ralentizan la labor judicial. A ello se suma la falta de sistemas tecnológicos especializados en el Poder Judicial del Cusco para automatizar la transcripción. También la capacitación del personal en herramientas digitales es insuficiente y dificulta la adopción de nuevas soluciones. Finalmente, el incremento en el volumen de audiencias virtuales ha generado una saturación administrativa que agrava la situación.

Las consecuencias de mantener este escenario son claras. El retraso en la emisión de actas afecta el principio de celeridad procesal, y los errores en la transcripción pueden distorsionar el contenido de las declaraciones, comprometiendo el derecho al debido proceso. La sobrecarga laboral del personal incrementa el riesgo de desgaste profesional y reduce la eficiencia institucional. A nivel general, esta situación genera una percepción de ineficiencia y falta de transparencia del sistema judicial.

Frente a este problema, el campo del reconocimiento automático del habla ofrece herramientas que pueden contribuir a resolverlo. Los sistemas de reconocimiento automáti-

co del habla convierten señales acústicas en texto de manera automatizada y han avanzado significativamente gracias al aprendizaje profundo. Radford et al. (2023) desarrollaron el modelo Whisper, entrenado con 680 000 horas de datos multilingües, y demostraron que la transcripción humana profesional supervisada supera consistentemente el 98 % de exactitud, estableciendo un punto de referencia que los sistemas automáticos aún buscan alcanzar en dominios especializados. Esta brecha significa que la adopción de estos sistemas en el ámbito judicial no puede hacerse de forma directa, sino que requiere integración con componentes de corrección lingüística y adaptación al dominio jurídico.

En el Perú, el Poder Judicial lanzó en 2023 el aplicativo *Transcriptor de Audiencias Versión Alfa 2* en la Corte Superior de Justicia de Sullana y posteriormente en Huaura, con el objetivo de automatizar la transcripción de audiencias virtuales y reducir la carga procesal del personal judicial (Poder Judicial del Perú, 2023). Según reportes institucionales, la herramienta permitió reducir el tiempo de elaboración de actas en un 30 % y disminuir los errores manuales en un 15 %, siendo el antecedente práctico más cercano al problema que esta investigación aborda. Por su parte, Larrea (2024) evaluó en el Poder Judicial de Junín el uso de Google Meet y un transcriptor basado en inteligencia artificial, encontrando mejoras perceptibles en los tiempos de gestión procesal de audiencias penales. Hasta la fecha no existen publicaciones académicas ni reportes técnicos que documenten la precisión de estas herramientas o su adaptabilidad a contextos con variaciones dialectales locales, lo que evidencia un vacío tanto académico como tecnológico que este trabajo busca cubrir.

La presente investigación propone el diseño, implementación y evaluación de un sistema automatizado de transcripción de audiencias judiciales empleando inteligencia artificial, orientado a mejorar la precisión y reducir los tiempos de transcripción en el Distrito Judicial de Cusco. El sistema integra herramientas existentes para el reconocimiento automático del habla en tiempo real, con detección de múltiples hablantes, y un modelo de lenguaje de gran escala para el mejoramiento lingüístico del texto y la generación de actas con formato oficial. Su desempeño se evalúa mediante un corpus lingüístico judicial construido a partir de grabaciones reales del Distrito Judicial de Cusco, utilizando métricas estándar como la tasa de error de palabras (WER), la tasa de error de caracteres (CER) y el Real-Time Factor (RTF). El aporte principal radica en la integración, adaptación y evaluación empírica de un sistema de inteligencia artificial contextualizado al ámbito judicial cusqueño, a diferencia de los estudios previos que solo comparan herramientas comerciales sin construir un corpus ni

evaluar el desempeño en condiciones locales reales.

3.1 Formulación de la Pregunta de Investigación

3.1.1 Problema General

¿En qué medida un sistema automatizado de transcripción de audiencias judiciales empleando inteligencia artificial mejora la precisión y reduce los tiempos de transcripción en el Distrito Judicial de Cusco?

3.1.2 Problemas Específicos

- a) ¿Cuáles son las limitaciones y dificultades del proceso actual de transcripción manual de audiencias judiciales en el Distrito Judicial de Cusco en términos de precisión, tiempo de entrega y carga administrativa?
- b) ¿Qué características técnicas y funcionales debe poseer un sistema automatizado de transcripción judicial basado en inteligencia artificial para garantizar precisión y eficiencia en el contexto del Distrito Judicial de Cusco?
- c) ¿Cómo diseñar e implementar un sistema automatizado de transcripción adaptado a las condiciones tecnológicas, lingüísticas y operativas del Distrito Judicial de Cusco?
- d) ¿En qué medida la implementación del sistema automatizado mejora la tasa de error de palabras (WER), reduce los tiempos de transcripción y eleva la satisfacción de los usuarios en comparación con el método manual?

4 Alcances y limitaciones

4.1 Delimitación Temporal

La presente investigación comprende el periodo entre noviembre de 2025 y junio de 2026. Durante este tiempo se recopilan los datos del corpus lingüístico judicial, se realizan las observaciones institucionales, se implementa el prototipo del sistema y se evalúa su desempeño técnico. Los audios utilizados para la construcción del corpus y la evaluación comparativa provienen de grabaciones de audiencias del Distrito Judicial de Cusco realiza-

das entre 2024 y 2025, que sirven como base de datos para medir mejoras en precisión y tiempo de transcripción respecto al método manual. El sistema desarrollado no se limita a este periodo: una vez validado, está diseñado para operar de forma continua a futuro.

4.2 Delimitación Espacial

El presente estudio se llevará a cabo en el Distrito Judicial de Cusco, Perú, específicamente en las salas donde se desarrollan audiencias tanto presenciales como virtuales. Este distrito ha incrementado de manera significativa el uso de plataformas digitales en la administración de justicia tras la pandemia de COVID-19, lo que ha puesto en evidencia las limitaciones del método manual de transcripción. La elección de este distrito se justifica porque representa un contexto donde la modernización digital es urgente y donde existe un volumen creciente de audiencias que demanda soluciones tecnológicas eficientes. Los resultados y el modelo tecnológico desarrollado podrán servir como referencia para su replicación en otros distritos judiciales del país.

5 Objetivos

5.1 Objetivo General

Diseñar, implementar y evaluar un sistema automatizado de transcripción de audiencias judiciales empleando inteligencia artificial que permita mejorar la precisión y reducir los tiempos de transcripción en el Distrito Judicial de Cusco.

5.2 Objetivos Específicos

- a) Analizar las limitaciones y dificultades del proceso actual de transcripción manual de audiencias judiciales en el Distrito Judicial de Cusco, identificando los principales factores que afectan la precisión, el tiempo de entrega y la carga administrativa del personal.
- b) Diseñar la arquitectura técnica y funcional de un sistema automatizado de transcripción judicial basado en inteligencia artificial, estableciendo sus módulos, flujos de datos, requerimientos de hardware y software, y niveles de precisión esperados.

- c) Implementar el prototipo del sistema automatizado de transcripción judicial empleando inteligencia artificial, integrando componentes de captura de audio, procesamiento, comunicación cliente-servidor y motor de reconocimiento de voz, a partir de un corpus lingüístico judicial construido con grabaciones del Distrito Judicial de Cusco.
- d) Evaluar el desempeño del sistema automatizado en comparación con el método manual, utilizando métricas cuantitativas de precisión (WER y CER), eficiencia temporal (RTF y tiempo de entrega de actas) y calidad percibida (MOS).

6 Reglamentación y transcripción de audiencias judiciales en el Perú

6.1 Marco legal que ordena el registro de las audiencias

El mandato de registrar y transcribir las actuaciones judiciales no proviene de una política institucional discrecional, sino de normas con rango de ley. El artículo 120 del Código Procesal Penal (Decreto Legislativo N.º 957) establece en su numeral primero que la actuación procesal fiscal o judicial se documenta por medio de acta, utilizando de ser posible los medios técnicos que correspondan. El numeral segundo precisa que el acta debe consignar la fecha indicando lugar, año, mes, día y hora, las personas que intervinieron y una relación sucinta o integral, según el caso, de los actos realizados. El numeral tercero introduce una disposición de especial relevancia para esta investigación al señalar que será posible la reproducción audiovisual de la actuación procesal, sin perjuicio de efectuarse la transcripción respectiva en un acta. Esta última disposición implica que la grabación audiovisual no exime al especialista de audiencia de la obligación de producir un documento escrito, lo que otorga fundamento legal directo al sistema automatizado propuesto.

El artículo 361 del mismo código establece que el juicio oral se documenta en acta, la cual debe contener una síntesis de lo actuado y ser firmada por el juez y el secretario. Por su parte, el artículo 136 autoriza al Consejo Ejecutivo del Poder Judicial a disponer la utilización de sistemas tecnológicos que se consideren necesarios para el registro, archivo, copia, transcripción y seguridad del expediente. Esta autorización legal ampara explícitamente el uso de herramientas de inteligencia artificial para automatizar la transcripción dentro del marco institucional del Poder Judicial.

En el ámbito civil, el artículo 204 del Código Procesal Civil modificado por la Ley N.º

30293 del 28 de diciembre de 2014, establece que la audiencia de pruebas es registrada en video o en audio en soporte individualizado que se incorpora al expediente. Solo cuando esto no sea posible se levanta acta escrita consignando lugar y fecha, nombre de intervinientes y resumen de lo actuado.

La Casación N.º 626-2021 emitida por la Sala Penal Permanente de la Corte Suprema ha reforzado el carácter obligatorio de la transcripción al establecer que las resoluciones orales deben transcribirse incluso cuando han sido impugnadas, dado el mandato constitucional de motivación escrita contenido en los artículos 139, numerales 5 y 20, de la Constitución Política del Perú.

6.2 Evolución normativa de las audiencias virtuales

La pandemia de COVID-19 aceleró la adopción formal de las audiencias virtuales en el Poder Judicial peruano. El 25 de junio de 2020, el Consejo Ejecutivo del Poder Judicial aprobó mediante la Resolución Administrativa N.º 000173-2020-CE-PJ el Protocolo Temporal para Audiencias Judiciales Virtuales durante el Período de Emergencia Sanitaria. Entre sus disposiciones relevantes se señala que solo el órgano jurisdiccional puede grabar la audiencia y que los jueces deben asegurar que la grabación sea de manera clara y sin interrupciones para una transcripción correcta del acta.

Lo que nació como un protocolo temporal fue declarado permanente mediante la Resolución Administrativa N.º 000213-2023-CE-PJ del 7 de junio de 2023, la cual además estableció que los jueces deben realizar las audiencias desde su despacho judicial, pudiendo elegir la modalidad virtual o presencial según las características del caso. La Resolución Administrativa N.º 000047-2026-CE-PJ emitida en enero de 2026 dejó sin efecto la Directiva N.º 005-2015-CE-PJ, actualizando el marco normativo a la realidad tecnológica actual.

6.3 Obligaciones del especialista judicial de audiencia

El Especialista Judicial de Realización de Audiencias es el funcionario responsable de dar fe pública de los actos procesales que ocurren durante la audiencia y de elaborar el acta correspondiente. Entre sus obligaciones se encuentran descargar y asociar las grabaciones de las audiencias en el sistema informático del Poder Judicial, elaborar las notificaciones

urgentes ordenadas durante la sesión y suscribir el acta junto al juez al concluir la audiencia.

El contenido mínimo del acta exigido por la normativa institucional comprende los datos de las partes asistentes, una descripción sucinta del desarrollo de la audiencia, y la numeración de cada resolución emitida con el resumen de sus fundamentos y la decisión adoptada. La obligación de transcribir se acentúa cuando se emiten resoluciones durante la audiencia que son susceptibles de impugnación, pues en estos casos la Corte Suprema ha establecido que la motivación escrita es exigible con independencia del registro audiovisual existente.

6.4 Confidencialidad y protección de datos en el registro judicial

El tratamiento de datos personales en el marco de las audiencias judiciales está regulado principalmente por la Ley N.º 29733, Ley de Protección de Datos Personales, y su nuevo reglamento aprobado mediante Decreto Supremo N.º 016-2024-JUS publicado el 30 de noviembre de 2024. El artículo 9 de esta ley establece el principio de seguridad que obliga al titular del banco de datos a adoptar medidas técnicas, organizativas y legales que garanticen la seguridad de los datos personales y eviten su alteración, pérdida, tratamiento o acceso no autorizado.

Para el Distrito Judicial de Cusco, esto implica que el sistema automatizado de transcripción debe contemplar mecanismos de cifrado en el transporte de datos, almacenamiento seguro de los archivos de audio y control de acceso basado en roles para garantizar que únicamente el personal autorizado acceda a los registros de las audiencias.

6.5 Normas sobre el uso de firmas digitales en actas judiciales

El Decreto Supremo N.º 052-2008-PCM regula el uso de la firma digital como mecanismo de autenticación de documentos electrónicos con plena validez jurídica equivalente a la firma manuscrita. El Poder Judicial ha iniciado la implementación de la firma digital en las actas de audiencia como parte de su programa de modernización digital, lo que permite que el juez y el especialista de audiencia suscriban el acta de forma remota garantizando su autenticidad.

El sistema automatizado propuesto contempla la integración de un flujo de aproba-

ción donde el acta generada a partir de la transcripción pasa por revisión del especialista de audiencia y posterior validación del juez antes de quedar en estado aprobado. Este flujo es consistente con los requisitos normativos vigentes y con la implementación progresiva de la firma digital en el Poder Judicial peruano.

7 Antecedentes (estado del arte)

7.1 Antecedentes a Nivel Internacional

7.1.1 Garneau y Bolduc (2024)

Garneau y Bolduc (2024) realizaron en la University of Copenhagen un estudio titulado *The State of Commercial Automatic French Legal Speech Recognition Systems and their Impact on Court Reporters*, cuyo propósito fue evaluar la viabilidad de emplear reconocimiento automático del habla en la transcripción de procesos judiciales, considerando su rendimiento técnico y las implicancias profesionales y legales.

El diseño fue experimental comparativo basado en la evaluación de tres modelos: Amazon Transcribe, Google Speech-to-Text y OpenAI Whisper. La muestra se conformó por audios reales de carácter judicial, incluyendo grabaciones de la *Commission Charbonneau* y sentencias de jueces, con un total aproximado de un día, seis horas y 37 minutos de material. Las transcripciones oficiales de taquígrafos profesionales sirvieron como referencia de comparación. Se utilizó la Word Error Rate (WER) considerando inserciones, eliminaciones y sustituciones. Amazon Transcribe obtuvo el mejor desempeño con un WER de 0,15, seguido de Google y Whisper.

Los autores concluyen que ninguno de los sistemas alcanzó la precisión requerida para prescindir de supervisión humana en el ámbito judicial y que los sistemas de reconocimiento automático del habla aún deben perfeccionarse para las demandas de exactitud en el contexto legal.

Este antecedente demuestra que los sistemas comerciales por sí solos no son suficientes para el ámbito judicial y requieren componentes adicionales de corrección. Esto justifica el enfoque adoptado en el presente trabajo de combinar el motor de reconocimiento automático del habla con un modelo de lenguaje para el mejoramiento lingüístico. Las métricas

WER empleadas sirven como referencia directa para el marco de evaluación propuesto.

7.1.2 Harrington (2023)

Harrington (2023) publicó en la Universidad de York el artículo *Incorporating Automatic Speech Recognition Methods into the Transcription of Police-Suspect Interviews*, abordando la baja calidad y subjetividad en las transcripciones de entrevistas policiales, con el objetivo de evaluar la viabilidad de integrar reconocimiento automático del habla para generar registros textuales fiables para uso como evidencia en tribunales.

El diseño fue experimental comparativo. La muestra consistió en grabaciones de dos corpus de inglés británico: el *Dynamic Variability in Speech database* con 100 hablantes y el *West Yorkshire Regional English Database* con 180 hablantes. Se evaluaron Amazon Transcribe, Google Cloud Speech-to-Text y Rev AI. La métrica principal fue el WER. Amazon Transcribe obtuvo el mejor desempeño, con tasas de error menores al 14 % en audio limpio, mientras que las tasas de error aumentaron significativamente con ruido de fondo.

La autora concluye que los sistemas automáticos pueden utilizarse como primer borrador de transcripciones siempre que exista edición humana posterior, y que la supervisión humana sigue siendo indispensable para garantizar la exactitud en contextos forenses.

Este estudio refuerza la necesidad de un flujo donde la transcripción automática sea revisada por el operador judicial antes de convertirse en acta oficial, lo cual es coherente con el diseño del sistema propuesto. Las variaciones de rendimiento según la calidad del audio alertan además sobre la importancia de las condiciones acústicas en las salas del Distrito Judicial de Cusco.

7.1.3 Loakes (2024)

Loakes (2024) publicó en *Frontiers in Communication* el artículo *Automatic Speech Recognition and the Transcription of Indistinct Forensic Audio*, analizando el desempeño de sistemas de reconocimiento automático del habla en audio forense indistinto, con el fin de evaluar cómo se comportan los modelos más recientes frente a grabaciones de baja calidad.

Se evaluaron múltiples sistemas con grabaciones forenses reales en condiciones adversas como ruido de fondo, solapamiento de voces y baja calidad técnica del audio. El

modelo Whisper obtuvo el mejor rendimiento en condiciones adversas, logrando transcribir el 68,9 % del material con un WER de 50 %. Estos valores contrastan notoriamente con los WER en audio limpio que suelen ubicarse por debajo del 10 %.

La autora concluye que la transcripción humana sigue siendo indispensable hasta que los sistemas automáticos alcancen mayor confiabilidad en condiciones adversas, y que los sistemas de reconocimiento automático del habla pueden complementar pero no reemplazar al transcriptor humano en entornos forenses.

7.1.4 Saadany, Orasan, Walker y Breslin (2025)

Saadany et al. (2025) publicaron en *Applied Sciences* de MDPI el artículo *Employing AI for Better Access to Justice: An Automatic Text-to-Video Linking Tool for UK Supreme Court Hearings*, en el que desarrollaron un sistema basado en reconocimiento automático del habla y modelos de lenguaje de gran escala para vincular automáticamente las sentencias escritas del Tribunal Supremo del Reino Unido con los segmentos de video de las audiencias correspondientes.

El sistema integra dos componentes: un motor ASR adaptado al dominio legal, entrenado con 139 horas de transcripciones editadas manualmente de audiencias judiciales y documentos legales, y un módulo de vinculación semántica basado en incrustaciones GPT adaptadas al corpus jurídico. Esta combinación redujo los errores de transcripción en un 9 % respecto a los motores genéricos y permitió una navegación automática por los momentos relevantes de cada audiencia.

Los autores concluyen que la adaptación al dominio legal mejora significativamente la precisión del reconocimiento, y que la combinación de ASR con modelos de lenguaje facilita tareas complejas de gestión documental en contextos jurídicos. Este antecedente es directamente relevante para el presente trabajo porque demuestra la viabilidad de integrar ASR y LLM en un mismo flujo de procesamiento judicial, que es exactamente el enfoque propuesto.

7.1.5 Lyra, Barbosa, Salazar, Argôlo y De Souza (2024)

Lyra et al. (2024) presentaron en las memorias del *16th International Joint Conference on Knowledge Discovery, Knowledge Engineering and Knowledge Management* el artículo *Automatic Transcription Systems: A Game Changer for Court Hearings*, en el que desarrollaron una solución de transcripción automática para audiencias del sistema judicial brasileño, contexto donde el proceso era hasta entonces completamente manual.

El sistema fue diseñado para obtener la mejor transcripción posible considerando las limitaciones tecnológicas actuales, la calidad de las grabaciones, la dicción de los participantes y la terminología jurídica. Los resultados mostraron mejoras significativas en los tiempos de elaboración de actas, demostrando la viabilidad de la automatización en el contexto judicial latinoamericano.

Los autores concluyen que los sistemas de transcripción automática representan un cambio significativo para las audiencias judiciales, aunque requieren adaptación al vocabulario especializado y supervisión humana. Este trabajo es uno de los antecedentes más cercanos por compartir el contexto latinoamericano y el dominio judicial, lo que valida la pertinencia del enfoque adoptado en la presente investigación.

7.2 Antecedentes a Nivel Nacional

7.2.1 Vera (2021)

Vera (2021) desarrolló en la Universidad Nacional Mayor de San Marcos el estudio titulado *STT: Un Sistema de Apoyo a la Transcripción de Audiencias Fiscales Usando Vosk*, publicado en la *Revista de Investigación de Sistemas e Informática*, con el objetivo de diseñar e implementar un sistema transcriptor en español para agilizar la transcripción de audiencias fiscales.

El sistema se apoyó en una arquitectura cliente-servidor utilizando VueJS para la interfaz, FastAPI para el backend, RabbitMQ y Celery como gestores de tareas asíncronas, y PostgreSQL para la gestión de datos. El motor de reconocimiento fue Vosk, un modelo de código abierto que opera localmente sin conexión a la nube. El autor concluye que el sistema demostró viabilidad técnica para apoyar la transcripción de audiencias fiscales en español, y

que la arquitectura con procesamiento asíncrono permitió gestionar múltiples audiencias de manera eficiente.

Este antecedente es relevante porque comparte componentes arquitectónicos similares a los del presente trabajo, como el uso de FastAPI, Celery y PostgreSQL. La diferencia principal radica en que el sistema propuesto emplea un servicio de reconocimiento del habla en la nube que ofrece transcripción en tiempo real con identificación automática de hablantes, en lugar del modelo local utilizado por Vera.

7.2.2 *Larrea (2024)*

Larrea (2024) evaluó en su tesis de maestría en la Universidad Nacional del Centro del Perú la influencia de Google Meet y un transcriptor basado en inteligencia artificial en la gestión de audiencias penales del Poder Judicial de Junín. El diseño fue cuasiexperimental de grupo único con mediciones antes y después de la implementación. La implementación contribuyó a una mayor celeridad en las audiencias virtuales frente a las presenciales, evidenciando mejoras perceptibles en los tiempos de gestión procesal.

El autor concluye que la combinación de plataformas de videoconferencia con herramientas de transcripción automática tiene un impacto positivo en la eficiencia de las audiencias penales dentro del Poder Judicial peruano. Este es el antecedente nacional más cercano porque evalúa transcripción con inteligencia artificial en el contexto judicial peruano. El diseño cuasiexperimental empleado sirve como referencia para la estrategia de evaluación del presente trabajo.

7.2.3 *Poder Judicial del Perú (2023)*

El Poder Judicial del Perú (2023) implementó el aplicativo *Transcriptor de Audiencias Versión Alfa 2* en la Corte Superior de Justicia de Sullana, con el propósito de disminuir la carga procesal mediante transcripciones automatizadas casi inmediatas, y lo extendió posteriormente a la Corte Superior de Huaura. Los indicadores reportados muestran una reducción del tiempo de elaboración de actas en un 30 % y una disminución de errores manuales en un 15 %.

Este es el antecedente práctico más directo para el presente trabajo. El aporte diferen-

cial de esta investigación consiste en construir un corpus judicial local y evaluar el sistema con métricas estándar en el contexto específico del Distrito Judicial de Cusco, lo que permitirá obtener evidencia empírica que trascienda los reportes institucionales.

7.3 Antecedentes a Nivel Local

En el ámbito del Distrito Judicial de Cusco no se identificaron publicaciones académicas que documenten la implementación o evaluación de sistemas de transcripción automática para audiencias. Este vacío refuerza la pertinencia de la presente investigación, que busca generar el primer referente empírico local en este campo mediante la construcción de un corpus lingüístico judicial propio y la medición de métricas objetivas en condiciones reales de funcionamiento. La ausencia de antecedentes locales también evidencia que la tecnología disponible a nivel nacional aún no ha sido adoptada ni evaluada en este contexto específico, lo que convierte a este trabajo en un aporte pionero para la gestión procesal de la región Cusco.

8 Marco teórico

8.1 Reglamentación y proceso de audiencia judicial en el Perú

8.1.1 Sistemas automatizados en entornos judiciales

Los sistemas automatizados en entornos judiciales se entienden como aplicaciones tecnológicas basadas en inteligencia artificial y algoritmos de procesamiento de información, cuyo propósito es apoyar o sustituir tareas rutinarias realizadas por los operadores de justicia. Estos sistemas abarcan desde la transcripción automática de audiencias hasta la clasificación documental y la gestión de expedientes digitales.

La incorporación de reconocimiento automático del habla en tribunales constituye un avance significativo hacia la justicia digital, aunque aún persisten limitaciones de precisión en contextos multilingües y con vocabulario especializado. Loakes (2024) advierte que los sistemas automatizados enfrentan problemas de exactitud en audios de baja calidad, lo que condiciona su fiabilidad como herramientas únicas para generar registros oficiales. La combinación de ASR con modelos de lenguaje de gran escala, como lo demuestra el trabajo

de Saadany et al. (2025) para el Tribunal Supremo del Reino Unido, ha permitido superar algunas de estas limitaciones en contextos judiciales específicos.

8.1.2 Valor legal de las actas de audiencia

Las actas de audiencia constituyen documentos públicos de carácter procesal con plena validez legal en el marco de los procesos judiciales peruanos. Según el Código Procesal Civil en su artículo 197 y el Código Procesal Penal en su artículo 120, las actas constituyen prueba preconstituida y registran de manera fidedigna los actos procesales, garantizando el principio de publicidad y el derecho de defensa.

El Poder Judicial del Perú (2023) ha señalado que la digitalización de las actas a través de grabaciones audiovisuales y su posterior transcripción debe cumplir con estándares de autenticidad, integridad y disponibilidad, tal como exige la Ley de Gobierno Digital N.º 1412 y el Decreto Legislativo N.º 681 sobre microformas digitales con valor legal.

8.1.3 Aspectos de redacción y estilo en actas

El lenguaje en las actas debe ser preciso, impersonal y formal. La normativa institucional recomienda el uso de tercera persona y tiempo presente, estructura clara numerada por actos procesales, e inclusión de firmas digitales o electrónicas para cerrar el documento. Los términos jurídicos deben usarse con precisión, evitando sinónimos que puedan generar ambigüedades en la interpretación posterior del acta.

8.2 Inteligencia Artificial y reconocimiento automático del habla

8.2.1 Fundamentos del reconocimiento automático del habla

El reconocimiento automático del habla es la tecnología que convierte señales acústicas en texto mediante la combinación de modelos acústicos, modelos de lenguaje y algoritmos de decodificación. El proceso se inicia con la conversión de la señal de audio cruda en una representación numérica que la red neuronal puede procesar. La señal de entrada $x(t)$ se segmenta en ventanas superpuestas de 25 ms con un paso de 10 ms. Para cada ventana se aplica la Transformada Rápida de Fourier y luego se proyecta sobre un banco de filtros de

escala Mel:

$$\text{Mel}(f) = 2595 \cdot \log_{10} \left(1 + \frac{f}{700} \right) \quad (1)$$

donde f es la frecuencia en Hertz. Esta escala imita la percepción auditiva humana, concentrando la resolución en las frecuencias bajas donde el oído humano es más sensible. El resultado es un espectrograma log-Mel $\mathbf{X} \in \mathbb{R}^{T \times F}$, donde T es el número de ventanas temporales y F es el número de filtros Mel, generalmente 80.

8.2.2 Arquitectura Transformer en reconocimiento del habla

Los modelos de reconocimiento automático del habla modernos utilizan la arquitectura Transformer. El mecanismo central es la autoatención multi-cabeza que permite al modelo ponderar la importancia relativa de cada segmento temporal de la señal:

$$\text{Attention}(Q, K, V) = \text{Softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (2)$$

donde Q (consulta), K (clave) y V (valor) son proyecciones lineales de la entrada y d_k es la dimensión de las claves. El factor $\sqrt{d_k}$ escala los productos punto para evitar gradientes inestables durante el entrenamiento. En la configuración multi-cabeza se ejecutan h mecanismos de atención en paralelo y sus salidas se concatenan:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O \quad (3)$$

donde cada $\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$ y W^O es una matriz de proyección de salida.

8.2.3 Función de pérdida CTC para transcripción en tiempo real

Para el entrenamiento de modelos de reconocimiento del habla orientados a la transcripción en tiempo real se emplea comúnmente la función de pérdida CTC (*Connectionist Temporal Classification*):

$$\mathcal{L}_{\text{CTC}} = -\ln \sum_{\pi \in \mathcal{B}^{-1}(\mathbf{y})} \prod_{t=1}^T p(\pi_t | \mathbf{x}) \quad (4)$$

donde $\mathbf{y}$ es la secuencia objetivo de caracteres o subpalabras, $\mathcal{B}^{-1}(\mathbf{y})$ es el conjunto de todas las alineaciones posibles que colapsan a $\mathbf{y}$ tras eliminar repeticiones y el token en blanco, y $p(\pi_t | \mathbf{x})$ es la probabilidad del token π_t en el instante t dado el audio de entrada $\mathbf{x}$.

8.2.4 Diarización de hablantes

La diarización de hablantes asigna a cada segmento de texto un identificador de hablante. Cada segmento de audio s_i se representa mediante un vector $\mathbf{e}_i \in \mathbb{R}^d$ extraído por una red neuronal entrenada para discriminar hablantes. La asignación se realiza minimizando:

$$\min_{\{C_k\}} \sum_{k=1}^K \sum_{\mathbf{e}_i \in C_k} \|\mathbf{e}_i - \boldsymbol{\mu}_k\|^2 \quad (5)$$

donde C_k es el conjunto de segmentos asignados al hablante k y $\boldsymbol{\mu}_k$ es el centroide del grupo. La similitud entre vectores se mide mediante similitud coseno:

$$\text{sim}(\mathbf{e}_i, \mathbf{e}_j) = \frac{\mathbf{e}_i \cdot \mathbf{e}_j}{\|\mathbf{e}_i\| \cdot \|\mathbf{e}_j\|} \quad (6)$$

8.2.5 Indicador de confianza por palabra

Para cada palabra transcrita w_t , el sistema proporciona un valor de confianza $c_t \in [0, 1]$ que representa la probabilidad posterior del modelo:

$$c_t = \max_{w \in \mathcal{V}} P(w \mid \mathbf{x}_{t-\delta:t+\delta}) \quad (7)$$

donde $\mathcal{V}$ es el vocabulario del modelo y $\mathbf{x}_{t-\delta:t+\delta}$ es el contexto acústico alrededor del instante t . En el sistema propuesto, las palabras con confianza inferior a un umbral $\theta = 0,7$ se resaltan visualmente en el canvas de transcripción para que el operador judicial las revise antes de validar el acta.

8.3 Servicio de reconocimiento automático del habla: Deepgram Nova-3

8.3.1 Descripción del servicio y evolución

Deepgram Nova-3 es el modelo de reconocimiento automático del habla de la empresa Deepgram, lanzado en febrero de 2025 como sucesor del modelo Nova-2. El modelo está basado en una arquitectura de aprendizaje profundo propietaria optimizada para operar en modo de flujo continuo con latencias inferiores a 300 ms, lo que lo hace especialmente adecuado para audiencias judiciales en vivo donde la inmediatez de la transcripción es crítica. Según Radford et al. (2023), los modelos ASR de gran escala entrenados con datos multilingües y multitarea logran generalizar bien a dominios especializados en configuración de transferencia cero sin necesidad de ajuste fino, lo que justifica el uso de servicios de nube de alto rendimiento como alternativa a modelos entrenados localmente.

El servicio está disponible en modalidad de flujo continuo mediante conexión WebSocket y en modalidad de procesamiento por lotes mediante una API REST. Ambas modalidades soportan español latinoamericano (código `es-419`), diarización integrada de hablantes, formato inteligente de puntuación e indicadores de confianza por palabra. La modalidad de flujo continuo permite además enviar hasta 100 términos clave por sesión, lo que facilita la adaptación del sistema al vocabulario jurídico especializado.

8.3.2 Parámetros de configuración para el contexto judicial

La configuración del servicio para el sistema propuesto incluye los parámetros que se detallan en la Tabla 1.

Cuadro 1: Parámetros de configuración del servicio de reconocimiento del habla en modo de flujo continuo

Parámetro	Valor	Descripción
model	nova-3	Modelo de reconocimiento del habla
language	es-419	Español latinoamericano
diarize	true	Detección automática de hablantes
smart_format	true	Formato inteligente de puntuación y capitalización
endpointing	500 ms	Tiempo de silencio para considerar fin de enunciado
interim_results	true	Resultados parciales durante el habla
utterance_end_ms	1000 ms	Tiempo máximo de espera para fin de turno
encoding	linear16	Audio PCM lineal de 16 bits
sample_rate	16000	Frecuencia de muestreo en Hz
channels	1	Audio mono
keyterms	hasta 100 términos	Vocabulario jurídico especializado por sesión

8.3.3 Transcripción en tiempo real durante audiencias en vivo

La transcripción en tiempo real es el modo de operación principal del sistema durante las audiencias en vivo. El audio se captura continuamente en el navegador del operador judicial a una frecuencia de muestreo de 16 kHz en formato mono de 16 bits. La señal se fragmenta en paquetes de 250 ms que se envían al servidor mediante protocolo WebSocket. El servicio procesa los fragmentos de forma incremental, devolviendo resultados parciales con la etiqueta `is_final=false` y resultados finales con la etiqueta `is_final=true`. Cada palabra incluye texto reconocido, marcas de tiempo de inicio y fin, identificador de hablante y valor de confianza.

8.3.4 Transcripción diferida de archivos pregrabados

La modalidad de procesamiento por lotes permite transcribir archivos de audio y video pregrabados fuera del contexto de una audiencia en vivo. Esta modalidad es especialmen-

te útil para recuperar audiencias que no pudieron transcribirse en tiempo real o para procesar grabaciones históricas del Distrito Judicial de Cusco. Los formatos de entrada soportados incluyen WAV, MP3, MP4, WebM, OGG y FLAC.

Cuadro 2: Comparación entre modalidades de transcripción del sistema

Característica	Tiempo real (flujo continuo)	Por lotes (pre-grabado)
Protocolo	WebSocket (flujo continuo)	REST (API pre-grabado)
Latencia	< 300 ms por fragmento	Depende del tamaño del archivo
Resultados parciales	Sí	No (resultado completo al finalizar)
Diarización	Nativa en tiempo real	Nativa con mayor precisión por contexto completo
Caso de uso	Audiencias en vivo	Audios y videos pregrabados
Precisión esperada	WER $\sim$ 8-12 % en audio limpio	WER $\sim$ 6-10 %

8.4 Modelo de lenguaje para mejoramiento de texto: Claude Sonnet

8.4.1 Descripción del modelo y su función en el sistema

Claude Sonnet es un modelo de lenguaje de gran escala desarrollado por Anthropic, basado en la arquitectura Transformer de tipo solo decodificador. En el sistema propuesto, el modelo cumple dos funciones principales: el mejoramiento lingüístico de los segmentos transcritos y la generación del acta judicial formal. La versión del modelo seleccionada para el presente trabajo corresponde a la familia Claude Sonnet disponible a través de la interfaz de programación de la plataforma Anthropic, cuyo identificador de acceso es `claude-sonnet-4-6`. Esta versión ofrece una ventana de contexto de un millón de tokens, lo que permite procesar transcripciones de audiencias completas en una sola llamada sin necesidad de fragmentar el contenido.

Los modelos de lenguaje de gran escala como Claude han demostrado capacidades destacadas en tareas de redacción legal, incluyendo la generación de documentos estructura-

dos, la corrección ortográfica con preservación del significado y la extracción de información clave de textos extensos (Saadany et al., 2025). El modelo destaca en tareas de corrección ortográfica, reformato estructurado y generación de documentos legales en español, idioma que ocupa una categoría de soporte de primer nivel en su arquitectura.

8.4.2 Arquitectura de generación autoregresiva

A diferencia del Transformer codificador-decodificador utilizado en modelos de reconocimiento del habla, el modelo de lenguaje emplea una arquitectura solo decodificador donde la generación de texto se realiza de forma autoregresiva. La probabilidad de una secuencia de tokens $\mathbf{y} = (y_1, y_2, \dots, y_n)$ se descompone como:

$$P(\mathbf{y}) = \prod_{t=1}^n P(y_t \mid y_1, \dots, y_{t-1}) \quad (8)$$

En cada paso el modelo aplica atención causal enmascarada para que cada token solo pueda considerar los tokens anteriores:

$$\text{CausalAttention}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}} + M\right) V \quad (9)$$

donde M es una matriz de enmascaramiento triangular inferior con $M_{ij} = 0$ si $i \geq j$ y $M_{ij} = -\infty$ en caso contrario, garantizando que las predicciones futuras no influyan en las actuales.

8.4.3 Control de temperatura en el mejoramiento de texto

Para el mejoramiento lingüístico de las transcripciones, el modelo se configura con una temperatura baja ($\tau = 0,3$) que favorece la predictibilidad y fidelidad al texto original. La distribución de probabilidad sobre el vocabulario se ajusta mediante:

$$P(y_t = w) = \frac{\exp(z_w/\tau)}{\sum_{w' \in \mathcal{V}} \exp(z_{w'}/\tau)} \quad (10)$$

donde z_w es el logit correspondiente al token w y τ es la temperatura. Valores de τ cercanos a cero producen salidas casi deterministas, mientras que valores altos generan texto

más diverso. Para la tarea de mejoramiento judicial se requiere temperatura baja para evitar que el modelo añada palabras no pronunciadas durante la audiencia.

8.5 Métricas y parámetros de evaluación

8.5.1 Word Error Rate y Character Error Rate

La Word Error Rate (WER) es la métrica de referencia más utilizada en la evaluación de sistemas de reconocimiento automático del habla. Su fórmula estándar es:

$$\text{WER} = \frac{S + D + I}{N} \times 100 \quad (11)$$

donde S representa sustituciones, D eliminaciones, I inserciones y N el número total de palabras de referencia (Garneau y Bolduc, 2024). Un valor de WER inferior al 10 % es aceptable en aplicaciones de alta exigencia como la transcripción judicial. La Character Error Rate (CER) aplica el mismo principio a nivel de caracteres y resulta especialmente útil para evaluar términos jurídicos compuestos que pueden presentar errores parciales de transcripción.

8.5.2 Métricas de latencia y tiempo de procesamiento

La latencia se define como el intervalo de tiempo que transcurre entre la entrada de la señal de audio y la generación de la transcripción correspondiente:

$$\text{Latencia (ms)} = t_{\text{salida}} - t_{\text{entrada}} \quad (12)$$

El tiempo de procesamiento puede expresarse mediante el Real-Time Factor (RTF):

$$\text{RTF} = \frac{t_{\text{procesamiento}}}{t_{\text{audio}}} \quad (13)$$

Un valor de RTF inferior a 1 indica que el sistema es más rápido que el tiempo real, lo cual es deseable para aplicaciones de audiencias en vivo. Para el sistema propuesto se espera un RTF inferior a 0,3 en modo de flujo continuo, dado que el procesamiento principal ocurre

en los servidores del proveedor del servicio.

8.5.3 Mean Opinion Score

El Mean Opinion Score (MOS) es una medida subjetiva de calidad percibida evaluada mediante una escala de 1 a 5 por expertos o usuarios del sistema. En el contexto del presente trabajo, el MOS será aplicado a los operadores judiciales del Distrito Judicial de Cusco para medir la percepción de mejora en la celeridad procesal y la calidad de las transcripciones generadas por el sistema automatizado.

8.5.4 Validación estadística

La validación estadística garantiza que los resultados obtenidos no sean producto del azar. Para la comparación entre el método manual y el sistema automatizado se empleará la prueba t para muestras relacionadas:

$$t = \frac{\bar{d}}{s_d / \sqrt{n}} \quad (14)$$

donde $\bar{d}$ es la media de las diferencias entre pares, s_d es la desviación estándar de las diferencias y n es el número de pares de observaciones. Si el valor de $p < 0,05$ se rechaza la hipótesis nula. En casos donde no se cumplan supuestos de normalidad, se empleará la prueba no paramétrica de Wilcoxon para muestras emparejadas (Larrea, 2024).

8.6 Desarrollo del sistema propuesto

8.6.1 Descripción general

El sistema hace uso de herramientas de inteligencia artificial ya existentes y consolidadas: un servicio de reconocimiento automático del habla para la transcripción en tiempo real y por lotes, y un modelo de lenguaje de gran escala para el mejoramiento lingüístico y la generación de actas con formato oficial. No se desarrolla ni entrena un modelo de inteligencia artificial propio. El aporte del sistema radica en la integración, adaptación y evaluación de estas herramientas en el contexto del Distrito Judicial de Cusco, utilizando un corpus lingüístico judicial construido a partir de grabaciones reales.

El sistema se estructura en dos etapas de implementación. La primera entrega un producto mínimo viable con transcripción en tiempo real, detección de múltiples hablantes, edición asistida y generación de actas. La segunda incorpora mejoras de precisión, procesamiento por lotes, flujo de aprobación de actas y exportación documental en formatos DOCX y PDF.

8.6.2 *Arquitectura de software*

La arquitectura de software ha sido diseñada bajo un modelo cliente-servidor distribuido, asegurando la interoperabilidad de los componentes y la posibilidad de integrarse con los sistemas de gestión documental existentes en el Poder Judicial. El sistema se compone de seis servicios principales orquestados mediante Docker Compose y desplegados sobre un servidor de producción VPS KVM 2 de Hostinger con un dominio web configurado. Estos servicios son: frontend Next.js 14, backend FastAPI, PostgreSQL 16, Redis, Celery worker, y nginx como proxy inverso.

8.6.3 Stack tecnológico

Cuadro 3: Stack tecnológico del sistema propuesto

Capa	Tecnología	Justificación
Frontend	Next.js 14	Framework React con App Router y renderizado del lado del servidor
	TypeScript	Tipado estático para reducir errores en desarrollo
	TipTap	Editor extensible para el canvas de transcripción
	Zustand	Gestor de estado ligero y reactivo
	wavesurfer.js	Reproductor de audio con forma de onda sincronizado
Backend	FastAPI	Framework web asíncrono con documentación OpenAPI automática
	SQLAlchemy async	ORM asíncrono con driver nativo para PostgreSQL
	Alembic	Gestión de migraciones de base de datos
	Celery + Redis	Cola de tareas para procesamiento por lotes
Base de datos	PostgreSQL 16	Base de datos relacional con soporte JSONB
Servicios IA	Deepgram Nova-3	Reconocimiento del habla en tiempo real y por lotes
	Claude Sonnet	Mejoramiento lingüístico y generación de actas
Infraestructura	VPS KVM 2 + Docker	Orquestación de servicios en producción con proxy inverso
Exportación	python-docx / xhtml2pdf	Generación de DOCX y PDF con formato oficial

8.6.4 Corpus lingüístico judicial

Para la evaluación del sistema se construirá un corpus lingüístico judicial a partir de grabaciones reales de audiencias del Distrito Judicial de Cusco, previa autorización institucional y bajo las disposiciones de la Ley N.º 29733. El corpus incluirá grabaciones de audiencias presenciales y virtuales de distintas especialidades (penal, laboral y familia), con una duración mínima de 20 minutos por audiencia y participación de al menos dos interlocutores. Las transcripciones de referencia serán elaboradas por personal judicial capacitado. Este corpus constituye el insumo central para calcular las métricas WER, CER y RTF del sistema en condiciones reales.

8.6.5 Diccionario jurídico local

El diccionario jurídico opera localmente sin dependencia de servicios externos. Emplea el algoritmo Soundex adaptado al español y distancia de Levenshtein para búsqueda aproximada. Se configuran hasta 100 términos clave jurídicos por sesión en el servicio de reconocimiento del habla, organizados por categorías: procesal penal, delitos, partes procesales, normativa y terminología regional de Cusco.

8.6.6 Modelo de datos

Cuadro 4: Entidades principales del modelo de datos

Entidad	Campos clave	Descripción
Audiencia	expediente, juzgado, tipo_audiencia, fecha, estado, audio_path	Sesión judicial con metadatos completos
Segmento	audiencia_id, speaker_id, texto_ia, texto_mejorado, texto_editado, timestamps, confianza	Unidad de transcripción con trazabilidad completa
Hablante	audiencia_id, speaker_id, rol, etiqueta, nombre	Rol procesal de cada hablante; hasta 15 roles disponibles
Acta	audiencia_id, contenido_llm, contenido_editado, version, estado, aprobada_por	Acta con historial y flujo de aprobación
AuditLog	accion, entidad_tipo, entidad_id, usuario_id	Registro de acciones críticas del sistema
Usuario	email, nombre, rol, password_hash	Roles: administrador, transcriptor, supervisor

8.6.7 Seguridad del sistema

La autenticación se implementa mediante tokens de acceso con renovación automática. Las contraseñas se almacenan con hashing bcrypt. Solo el texto se envía al modelo de lenguaje, nunca el audio original. El transporte se asegura mediante HTTPS con nginx como terminación de cifrado en producción, garantizando la confidencialidad de los datos conforme a la Ley N.º 29733.

8.7 Marco Conceptual

8.7.1 *Inteligencia Artificial*

La inteligencia artificial es un campo de la informática que busca desarrollar sistemas capaces de realizar tareas que normalmente requieren inteligencia humana, tales como el aprendizaje, el razonamiento, la planificación y el reconocimiento de patrones. En el sistema propuesto, la inteligencia artificial habilita el reconocimiento de voz en tiempo real y el mejoramiento lingüístico del texto transcrito.

8.7.2 *Reconocimiento Automático del Habla*

El reconocimiento automático del habla es una tecnología que convierte señales acústicas en texto mediante la combinación de modelos acústicos, modelos de lenguaje y algoritmos de decodificación. Para la presente investigación, el reconocimiento automático del habla constituye el componente central del sistema, pues sustituye la transcripción manual de audiencias reduciendo tiempos y carga administrativa (Radford et al., 2023).

8.7.3 *Transcripción Judicial*

La transcripción judicial es el procedimiento que convierte en texto escrito las declaraciones orales, intervenciones y decisiones emitidas en una audiencia. Esta actividad es fundamental para garantizar el derecho al debido proceso, ya que el acta de audiencia se constituye en un documento oficial que respalda las actuaciones judiciales (Poder Judicial del Perú, 2023).

8.7.4 *Celeridad Procesal*

La celeridad procesal es un principio rector de la justicia que busca que los procesos se desarrollen en un plazo razonable y sin dilaciones indebidas. Este principio se encuentra consagrado en la Constitución Política del Perú y en tratados internacionales como la Convención Americana sobre Derechos Humanos. La implementación de sistemas de transcripción automática contribuye directamente a este principio al reducir el tiempo de entrega de actas y resoluciones.

8.7.5 *WebSocket*

WebSocket es un protocolo que establece un canal de comunicación bidireccional persistente entre cliente y servidor, reduciendo la latencia en el intercambio de datos. Esta característica es crucial en entornos judiciales donde la inmediatez en la transcripción de declaraciones puede incidir en la toma de decisiones durante la audiencia.

8.7.6 *Word Error Rate*

El WER es la métrica estándar para evaluar la precisión de los sistemas de reconocimiento automático del habla, calculada mediante la fórmula $WER = (S + D + I) / N \times 100$, donde S representa sustituciones, D eliminaciones, I inserciones y N el total de palabras de referencia. Un valor inferior al 10 % es aceptable en aplicaciones de alta exigencia como la transcripción judicial (Garneau y Bolduc, 2024).

8.7.7 *FastAPI*

FastAPI es un framework web moderno de Python diseñado para construir interfaces de programación de aplicaciones de alto rendimiento con tipado estático y generación automática de documentación. En el sistema propuesto, FastAPI coordina la autenticación, la gestión de audiencias, la persistencia en base de datos, la ejecución de tareas diferidas y la comunicación en tiempo real con el frontend.

8.7.8 *PostgreSQL*

PostgreSQL es un sistema de gestión de bases de datos relacional de código abierto reconocido por su robustez y cumplimiento de estándares SQL. En su versión 16 incorpora soporte nativo para datos semiestructurados mediante el tipo JSONB, lo que permite almacenar información flexible como las palabras individuales con marcas de tiempo y confianza de cada segmento de transcripción.

8.7.9 *Docker*

Docker es una plataforma de virtualización a nivel de contenedores que permite empaquetar aplicaciones con todas sus dependencias en unidades aisladas y reproducibles. En el sistema propuesto, Docker Compose orquesta los seis servicios del sistema, asegurando un despliegue reproducible en cualquier entorno servidor.

9 Metodología de la investigación

9.1 Metodología de Investigación

La metodología constituye el eje central de la investigación, pues permite organizar y ejecutar de manera sistemática las fases del proyecto, garantizando la validez y reproducibilidad de los resultados obtenidos. El presente trabajo busca diseñar, implementar y evaluar un sistema automatizado de transcripción de audiencias judiciales empleando inteligencia artificial, específicamente mediante la integración de un servicio de reconocimiento automático del habla en tiempo real y un modelo de lenguaje para el mejoramiento lingüístico y la generación de actas judiciales. La metodología se fundamenta en el enfoque de investigación aplicada de desarrollo tecnológico, centrada en la construcción, prueba y validación de un prototipo funcional orientado a mejorar la precisión y eficiencia de la transcripción judicial en el Distrito Judicial de Cusco.

9.2 Tipo y Alcance de Investigación

9.2.1 *Tipo de Investigación*

La investigación es de tipo aplicada y de desarrollo tecnológico, dado que busca generar una solución informática para un problema real del sistema judicial. La investigación aplicada se caracteriza por la utilización del conocimiento científico para el diseño de soluciones prácticas (Hernández-Sampieri et al., 2022). El estudio adopta un alcance tecnológico-evaluativo, en tanto evalúa el desempeño de la solución implementada sobre un corpus de audios judiciales reales a partir de métricas técnicas como WER, CER, RTF y MOS.

9.2.2 *Método de Investigación*

El método adoptado es experimental de tipo pre-experimental, ya que se comparan los resultados obtenidos antes y después de la implementación del sistema, utilizando el mismo conjunto de audios judiciales como base. Se evalúa la precisión de las transcripciones manuales frente a las generadas automáticamente por el sistema, midiendo mejoras en tiempo y exactitud. En paralelo, el desarrollo del software sigue el método ágil bajo el marco Scrum, lo que permite gestionar iterativamente el ciclo de vida del sistema con entregas periódicas validadas por los usuarios del Distrito Judicial.

9.2.3 *Diseño de Investigación*

El diseño de investigación es experimental de un solo grupo, orientado a comparar la precisión y eficiencia del proceso de transcripción judicial antes y después de la implementación del sistema automatizado. Las métricas evaluadas incluyen WER, CER, MOS y latencia promedio, las cuales permiten cuantificar el desempeño del sistema en condiciones reales.

9.2.4 *Enfoque de Investigación*

El enfoque es cuantitativo de validación tecnológica, dado que los resultados se expresan mediante indicadores numéricos de desempeño del sistema, calculados con métodos objetivos estandarizados en el campo del procesamiento de lenguaje natural (Garneau y Bolduc, 2024; Loakes, 2024). Complementariamente se incluye un análisis descriptivo que contextualiza los resultados en el entorno judicial, permitiendo formular recomendaciones para su adopción institucional.

9.3 **Corpus y Unidad de Análisis**

El corpus está constituido por grabaciones de audiencias del Distrito Judicial de Cusco obtenidas con autorización institucional y sujetas a las disposiciones de la Ley N.º 29733. Las grabaciones provienen de audiencias presenciales y virtuales de distintas especialidades: penal, laboral y familia. Cada grabación tiene una duración mínima de 20 minutos y cuenta con la participación de al menos dos interlocutores.

Las transcripciones de referencia son elaboradas por personal judicial capacitado, quienes transcriben fielmente el contenido de cada audiencia. La unidad de análisis es el segmento de transcripción: fragmento de texto producido por el sistema para un hablante identificado, que se contrasta con el fragmento equivalente en la transcripción de referencia.

9.4 Población y Muestra

Para la evaluación del sistema se seleccionarán de manera intencional 30 audiencias del Distrito Judicial de Cusco, distribuidas entre las especialidades penal, laboral y familiar, con criterio de equilibrio entre casos de alta y baja complejidad acústica. El criterio de selección incluye audios con una duración mínima de 20 minutos y participación de al menos dos interlocutores. La muestra se considera suficiente para calcular las métricas de error y precisión con resultados estadísticamente relevantes, conforme a lo utilizado en estudios similares (Garneau y Bolduc, 2024; Harrington, 2023).

9.5 Técnicas e Instrumentos de Recolección de Datos

La técnica principal es la observación directa no participante, registrando los audios de las audiencias seleccionadas y recopilando sus transcripciones manuales de referencia. Los instrumentos utilizados incluyen grabadora digital para captura de audio en alta calidad, script en Python para el preprocesamiento y normalización de los archivos de audio, el sistema automatizado desarrollado con FastAPI para la generación de transcripciones automáticas, y fichas de registro para almacenar los resultados de WER, CER, RTF y tiempo de entrega de actas.

Adicionalmente, se aplicará una encuesta de satisfacción a los operadores judiciales que utilicen el sistema, usando una escala Likert de 5 puntos para medir la percepción de mejora en la celeridad procesal y la calidad de las transcripciones (MOS).

10 Cronograma de actividades

El desarrollo de la investigación se llevará a cabo a lo largo de 3 meses, abarcando desde la revisión teórica y construcción del corpus hasta la evaluación del sistema y redacción final del documento de tesis.

Cuadro 5: Cronograma de actividades (3 meses)

Actividad	Mes 1	Mes 2	Mes 3
1. Revisión de literatura y diseño arquitectónico	X		
2. Construcción del corpus judicial	X		
3. Implementación del prototipo e integración de IA	X	X	
4. Pruebas y despliegue del sistema		X	
5. Validación empírica y recolección de métricas		X	X
6. Análisis de resultados y redacción del documento			X
7. Revisiones finales y sustentación			X

11 Presupuesto

El presupuesto del proyecto considera todos los recursos necesarios para el desarrollo e implementación del sistema automatizado de transcripción durante los 3 meses de investigación. Los costos se dividen en cuatro categorías: recursos humanos, servicios de inteligencia artificial, infraestructura tecnológica y materiales y otros gastos. Los valores están expresados en soles peruanos (S/) considerando un tipo de cambio referencial de S/ 3,70 por dólar americano.

11.1 Recursos Humanos

Cuadro 6: Presupuesto de recursos humanos

Rol	Días	Tarifa mín. (S/)	Tarifa máx. (S/)	Costo estimado (S/)
Ingeniero de sistemas (desarrollo del sistema)	60	100	200	9,000
Subtotal recursos humanos				9,000

11.2 Servicios de Inteligencia Artificial

Cuadro 7: Presupuesto de servicios de inteligencia artificial

Servicio (Plataforma IA)	Precio (USD)	T.C. Referencial	Costo est. (S/)
Recarga API Deepgram (Reconocimiento del habla)	\$200	3,70	740
Recarga API Claude (Mejoramiento y procesamiento)	\$100	3,70	370
Subtotal servicios IA	\$300		1,110

11.3 Infraestructura Tecnológica

Cuadro 8: Presupuesto de infraestructura tecnológica

Recurso	Tiempo	Costo base (S/)	Costo total (S/)
Servidor de producción (VPS)	1 año	350	350
Dominio web de la plataforma	1 año	40	40
Subtotal infraestructura			390

11.4 Materiales y Otros Gastos

Cuadro 9: Presupuesto de materiales y otros gastos

Concepto	Cantidad	Costo (S/)
Micrófono de grabación para corpus	1	200
Material de impresión y anillado	–	150
Movilidad para visitas institucionales	–	200
Imprevistos	–	250
Subtotal materiales y otros		800

11.5 Resumen General del Presupuesto

Cuadro 10: Resumen general del presupuesto del proyecto

Categoría	Costo total (S/)
Recursos humanos	9,000
Servicios de inteligencia artificial	1,110
Infraestructura tecnológica	390
Materiales y otros gastos	800
TOTAL GENERAL	11,300

El presupuesto total estimado del proyecto asciende a S/ 11,300. El componente de recursos humanos refleja el trabajo intensivo de programación e implementación, mientras que los costos de procesamiento en la nube y las recargas aseguran una capacidad holgada de recursos para testeo y uso de operarios, logrando que el producto digital sea totalmente funcional dentro del cronograma.

Referencias

- [1] Garneau, G., y Bolduc, P. (2024). The state of commercial automatic French legal speech recognition systems and their impact on court reporters. *arXiv preprint arXiv:2408.11940*. <https://arxiv.org/abs/2408.11940>
- [2] Harrington, L. (2023). Incorporating automatic speech recognition methods into the transcription of police-suspect interviews: Factors affecting automatic performance. *Frontiers in Communication*, 8, Article 1165233. <https://doi.org/10.3389/fcomm.2023.1165233>
- [3] Hernández-Sampieri, R., Fernández Collado, C., y Baptista Lucio, P. (2022). *Metodología de la investigación* (7.^a ed.). McGraw-Hill.
- [4] Larrea, P. (2024). *Uso de la plataforma Google Meet y transcriptor IA en el proceso de trámite de las audiencias del módulo penal dentro del Poder Judicial de Junín en la sub sede central Huancayo 2024* [Tesis de maestría, Universidad Nacional del Centro del Perú]. <https://repositorio.uncp.edu.pe/handle/20.500.12894/12608>

- [5] Loakes, D. (2024). Automatic speech recognition and the transcription of indistinct forensic audio: How do the new generation of systems fare? *Frontiers in Communication*, 9, Article 1281407. <https://doi.org/10.3389/fcomm.2024.1281407>
- [6] Lyra, A., Barbosa, C. E., Salazar, H., Argôlo, M., Lima, Y., Motta, R., y De Souza, J. M. (2024). Automatic transcription systems: A game changer for court hearings. En *Proceedings of the 16th International Joint Conference on Knowledge Discovery, Knowledge Engineering and Knowledge Management* (pp. 163–174). SCITEPRESS. <https://doi.org/10.5220/0012891400003838>
- [7] Poder Judicial del Perú. (2023). *Transcriptor de Audiencias Versión Alfa 2: Implementación en la Corte Superior de Justicia de Sullana*. Consejo Ejecutivo del Poder Judicial.
- [8] Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., y Sutskever, I. (2023). Robust speech recognition via large-scale weak supervision. En *Proceedings of the 40th International Conference on Machine Learning* (Vol. 202, pp. 28492–28518). PMLR. <https://proceedings.mlr.press/v202/radford23a.html>
- [9] Saadany, H., Breslin, C., Oraşan, C., y Walker, S. (2025). Employing AI for better access to justice: An automatic text-to-video linking tool for UK Supreme Court hearings. *Applied Sciences*, 15(16), 9205. <https://doi.org/10.3390/app15169205>
- [10] Vera, L. (2021). STT: Un sistema de apoyo a la transcripción de audiencias fiscales usando Vosk. *Revista de Investigación de Sistemas e Informática*, 18(1), 45–57. <https://doi.org/10.15381/risi.v18i1.21864>