

UNIVERSIDAD NACIONAL DE SAN ANTONIO ABAD DEL CUSCO

**FACULTAD DE INGENIERÍA ELÉCTRICA, ELECTRÓNICA, INFORMÁTICA Y
MECÁNICA**

ESCUELA PROFESIONAL DE INGENIERÍA INFORMÁTICA Y DE SISTEMAS



PLAN DE TESIS

**SISTEMA AUTOMATIZADO DE TRANSCRIPCIÓN DE
AUDIENCIAS JUDICIALES
EMPLEANDO INTELIGENCIA ARTIFICIAL EN EL
DISTRITO JUDICIAL DE CUSCO**

Tesis para optar al título profesional de:

INGENIERO INFORMÁTICO Y DE SISTEMAS

Presentado por:

Br. JESÚS ABRAHAM UCHIRI QUISPE

Código: 080227

Br. CARLA PALOMA CUETO SÁNCHEZ

Código: 120008

Asesor:

Lic. JOSÉ MAURO PILLCO QUISPE

CUSCO – PERÚ

2026

Índice general

Lista de Tablas	6
1 PLANTEAMIENTO DE LA INVESTIGACIÓN	1
1.1 Planteamiento del Problema	1
1.2 Formulación de la Pregunta de Investigación	3
1.2.1 Problema General	3
1.2.2 Problemas Específicos	3
1.3 Objetivos de la Investigación	4
1.3.1 Objetivo General	4
1.3.2 Objetivos Específicos	4
1.4 Justificación de la Investigación	5
1.4.1 Por su Conveniencia	5
1.4.2 Por su Relevancia	5
1.4.3 Por sus Implicancias Prácticas	6
1.4.4 Por su Valor Teórico	6
1.4.5 Por su Valor Metodológico	7
1.5 Delimitación del Estudio	7
1.5.1 Delimitación Temporal	7
1.5.2 Delimitación Espacial	7
2 MARCO TEÓRICO	9
2.1 Antecedentes	9
2.1.1 Antecedentes a Nivel Internacional	9
2.1.2 Antecedentes a Nivel Nacional	11
2.1.3 Antecedentes a Nivel Local	12
2.2 Marco Normativo y Operativo del Proceso de Audiencia Judicial	13

2.2.1	Concepto de Sistemas Automatizados en Entornos Judiciales	13
2.2.2	Valor Legal de las Actas de Audiencia	13
2.2.3	Normativa Aplicable al Uso de Sistemas Automatizados	14
2.2.4	Procedimiento en una Sala de Audiencia	14
2.2.5	Adaptación del Sistema ASR para Uso Judicial	14
2.2.6	Aspectos de Redacción y Estilo en Actas	15
2.2.7	Consideraciones Éticas y de Transparencia	15
2.2.8	Inteligencia Artificial Aplicada al Reconocimiento de Voz	15
2.2.9	Calidad en la Transcripción de Audiencias Virtuales	16
2.3	Diseños de Sistemas de Transcripción Automática	16
2.3.1	Modelos de Diseño Híbrido DNN-HMM	16
2.3.2	Modelos ASR Multilingües y Servicios Comerciales	17
2.3.3	Modelos Cliente-Servidor y Arquitecturas Distribuidas	19
2.3.4	Modelos Multimodales y Fusión de Señales	20
2.4	Métricas y Parámetros de Evaluación	21
2.4.1	Word Error Rate (WER) y Sonnex Distance	22
2.4.2	Métricas de Latencia y Tiempo de Procesamiento	23
2.4.3	Parámetros Acústicos y de Entrenamiento	24
2.4.4	Validación Estadística	25
2.5	Desarrollo del Proyecto	26
2.5.1	Arquitectura de Software	26
2.5.2	Stack Tecnológico	27
2.5.3	Servicios Externos de Inteligencia Artificial	27
2.5.4	Corpus Lingüístico Judicial	28
2.5.5	Interfaz de Usuario	28
2.5.6	Captura y Almacenamiento de Audio	29
2.5.7	Módulo de Transcripción en Tiempo Real	29
2.5.8	Módulo del Diccionario Jurídico	29
2.5.9	Módulo de Generación de Actas	29
2.5.10	Módulo de Exportación Documental	30
2.5.11	Modelo de Datos	30
2.5.12	Seguridad del Sistema	31

2.5.13	Metodología de Desarrollo de Software	31
2.6	Marco Conceptual	31
2.6.1	Inteligencia Artificial (IA)	31
2.6.2	Reconocimiento Automático del Habla	32
2.6.3	Transcripción Judicial	32
2.6.4	Celeridad Procesal	32
2.6.5	Eficiencia Institucional	33
2.6.6	FastAPI	33
2.6.7	WebSocket	33
2.6.8	Deepgram	33
2.6.9	Next.js	34
2.6.10	Whisper y faster-whisper	34
2.6.11	Word Error Rate (WER)	34
2.6.12	Claude (Anthropic)	35
2.6.13	TipTap	35
2.6.14	PostgreSQL	35
2.6.15	Docker	36
2.6.16	Redis	36
3	METODOLOGÍA	37
3.1	Metodología de Investigación	37
3.2	Tipo y Alcance de Investigación	38
3.2.1	Tipo de Investigación	38
3.2.2	Método de Investigación	38
3.2.3	Diseño de Investigación	38
3.2.4	Enfoque de Investigación	39
3.3	Corpus y Unidad de Análisis	39
3.4	Población y Muestra	39
3.5	Técnicas e Instrumentos de Recolección de Datos	40
3.6	Presupuesto	40
3.6.1	Recursos de Software y Servicios en la Nube	40
3.6.2	Presupuesto Total	41
3.6.3	Cronograma de Actividades	41

Referencias

42

Índice de cuadros

2.1	Arquitectura del modelo híbrido DNN-HMM	17
2.2	Comparación de modelos ASR multilingües y comerciales	18
2.3	Métricas de desempeño de modelos ASR	18
2.4	Parámetros y estrategias de entrenamiento	19
2.5	Validación y tipos de error evaluados	19
2.6	Componentes clave en modelos cliente-servidor y arquitecturas distribuidas para sistemas ASR judiciales	20
2.7	Tipos de fusión de señales en modelos multimodales para ASR judicial . . .	21
2.8	Métricas y parámetros de evaluación en sistemas ASR judiciales	22
2.9	Métricas de evaluación léxica y fonética en sistemas ASR	23
2.10	Métricas de evaluación de desempeño en sistemas ASR	24
2.11	Parámetros acústicos y de entrenamiento en modelos ASR	25
2.12	Stack tecnológico del sistema	27
2.13	Entidades principales del modelo de datos	30
3.1	Costos de software y servicios en la nube	40
3.2	Presupuesto total de la investigación	41
3.3	Cronograma de actividades de la investigación	41

CAPÍTULO 1

PLANTEAMIENTO DE LA INVESTIGACIÓN

1.1 Planteamiento del Problema

En el Distrito Judicial de Cusco, el registro de las audiencias judiciales —tanto presenciales como virtuales— se realiza mediante transcripción manual a cargo de secretarios y especialistas de audiencia. Esta práctica genera retrasos en la elaboración de actas, acumula errores derivados de la fatiga y la velocidad del dictado, y representa una carga administrativa significativa sobre el personal judicial. Como consecuencia, se pone en riesgo la calidad y confiabilidad de los registros procesales, situación que se ha agravado con el creciente uso de audiencias virtuales a partir de la pandemia de COVID-19.

Las causas de esta problemática son múltiples. En primer lugar, persiste una fuerte dependencia de métodos manuales tradicionales que ralentizan la labor judicial. A ello se suma la ausencia de sistemas tecnológicos especializados en el Poder Judicial del Cusco que permitan automatizar el proceso de transcripción. Asimismo, la capacitación del personal en herramientas digitales sigue siendo insuficiente, lo que dificulta la adopción de soluciones emergentes. Finalmente, el incremento en el volumen de audiencias virtuales ha generado una saturación administrativa que agrava la situación existente.

Las consecuencias de mantener este escenario son evidentes. El retraso en la emisión de actas atenta contra el principio de celeridad procesal, mientras que los errores en la transcripción pueden distorsionar el contenido de las declaraciones, comprometiendo el derecho al debido proceso. La sobrecarga laboral del personal incrementa el riesgo de desgaste profesional y reduce la eficiencia institucional. En un nivel más amplio, esta situación alimenta la percepción de ineficiencia y falta de transparencia del sistema judicial.

Frente a este escenario, el campo del reconocimiento automático del habla (ASR) ofrece herramientas que pueden contribuir a resolver el problema. Los sistemas ASR con-

vierten señales acústicas en texto de manera automatizada y han experimentado avances significativos en los últimos años gracias al aprendizaje profundo. Sin embargo, estudios recientes muestran que incluso los modelos más robustos, como Whisper y Deepgram Nova, mantienen tasas de error relevantes en condiciones reales con ruido de fondo, múltiples hablantes y vocabulario técnico especializado, mientras que la transcripción humana profesional supervisada supera consistentemente el 98 % de exactitud (Radford et al., 2023). Esta brecha implica que la adopción de sistemas ASR en el ámbito judicial no puede realizarse de forma directa, sino que requiere una integración cuidadosa con componentes de corrección lingüística y adaptación al dominio jurídico.

En América Latina, la adopción de sistemas ASR en entornos judiciales es aún incipiente. Los países de la región presentan brechas profundas en infraestructura digital, capacidades institucionales y preparación tecnológica, factores que dificultan el despliegue de herramientas de inteligencia artificial en procesos críticos (Bassey, Mulligan y Ojo, 2022). Aunque la región representa aproximadamente el 14 % de las visitas globales a soluciones de inteligencia artificial, solo recibe alrededor del 1,12 % de la inversión mundial en IA (CEPAL, 2025). En contextos donde sí se ha implementado ASR para procesos de documentación institucional, los resultados muestran mejoras relevantes en eficiencia: Zuchowski y Göller (2022) encontraron que la transcripción mediante ASR permite completar formularios en un promedio de 5,11 minutos frente a los 8,9 minutos requeridos por la digitación tradicional, lo que representa una mejora del 43 % en eficiencia temporal.

En el Perú, el Poder Judicial lanzó en 2023 el aplicativo *Transcriptor de Audiencias Versión Alfa 2* en la Corte Superior de Justicia de Sullana y, posteriormente, en Huaura, con el objetivo de automatizar la transcripción de audiencias virtuales y reducir la carga procesal del personal judicial (Poder Judicial del Perú, 2023). Según reportes institucionales, la herramienta permitió reducir el tiempo de elaboración de actas en un 30 % y disminuir los errores manuales en un 15 %, constituyendo el antecedente práctico más cercano al problema que esta investigación aborda. No obstante, hasta la fecha no existen publicaciones académicas ni reportes técnicos que documenten su precisión, funcionamiento lingüístico o adaptabilidad a contextos con variaciones dialectales. Esto evidencia un vacío tanto académico como tecnológico que esta investigación busca abordar.

La presente investigación propone el diseño, implementación y evaluación de un sis-

tema automatizado de transcripción de audiencias judiciales empleando inteligencia artificial, orientado a mejorar la precisión y reducir los tiempos de transcripción en el Distrito Judicial de Cusco. El sistema integra herramientas existentes: Deepgram Nova-2 para el reconocimiento automático del habla en tiempo real con detección de múltiples hablantes, y Claude 3.5 Sonnet para el mejoramiento lingüístico del texto y la generación de actas con formato oficial. Su desempeño se evalúa mediante un corpus lingüístico judicial construido a partir de grabaciones reales del Distrito Judicial de Cusco, utilizando métricas estándar del campo ASR como la tasa de error de palabras (WER), la tasa de error de caracteres (CER) y el Real-Time Factor (RTF). De este modo, el aporte principal radica en la integración, adaptación y evaluación empírica de un sistema de inteligencia artificial contextualizado al ámbito judicial cusqueño, diferenciándose de los estudios previos que únicamente comparan herramientas comerciales sin construir un corpus ni evaluar el desempeño en condiciones locales reales.

1.2 Formulación de la Pregunta de Investigación

1.2.1 Problema General

¿En qué medida un sistema automatizado de transcripción de audiencias judiciales empleando inteligencia artificial mejora la precisión y reduce los tiempos de transcripción en el Distrito Judicial de Cusco?

1.2.2 Problemas Específicos

- a) ¿Cuáles son las limitaciones y dificultades del proceso actual de transcripción manual de audiencias judiciales en el Distrito Judicial de Cusco, en términos de precisión, tiempo de entrega y carga administrativa?
- b) ¿Qué características técnicas y funcionales debe poseer un sistema automatizado de transcripción judicial basado en inteligencia artificial para garantizar precisión y eficiencia en el contexto del Distrito Judicial de Cusco?
- c) ¿Cómo diseñar e implementar un sistema automatizado de transcripción adaptado a las condiciones tecnológicas, lingüísticas y operativas del Distrito Judicial de Cusco?

- d) ¿En qué medida la implementación del sistema automatizado mejora la tasa de error de palabras (WER), reduce los tiempos de transcripción y eleva la satisfacción de los usuarios en comparación con el método manual?

1.3 Objetivos de la Investigación

1.3.1 Objetivo General

Diseñar, implementar y evaluar un sistema automatizado de transcripción de audiencias judiciales empleando inteligencia artificial, que permita mejorar la precisión y reducir los tiempos de transcripción en el Distrito Judicial de Cusco.

1.3.2 Objetivos Específicos

- a) Analizar las limitaciones y dificultades del proceso actual de transcripción manual de audiencias judiciales en el Distrito Judicial de Cusco, identificando los principales factores que afectan la precisión, el tiempo de entrega y la carga administrativa del personal.
- b) Diseñar la arquitectura técnica y funcional de un sistema automatizado de transcripción judicial basado en inteligencia artificial, estableciendo sus módulos, flujos de datos, requerimientos de hardware y software, y niveles de precisión esperados.
- c) Implementar el prototipo del sistema automatizado de transcripción judicial empleando inteligencia artificial, integrando componentes de captura de audio, procesamiento, comunicación cliente-servidor y motor de reconocimiento de voz, a partir de un corpus lingüístico judicial construido con grabaciones del Distrito Judicial de Cusco.
- d) Evaluar el desempeño del sistema automatizado en comparación con el método manual, utilizando métricas cuantitativas de precisión (WER, CER), eficiencia temporal (RTF, tiempo de entrega de actas) y calidad percibida (MOS).

1.4 Justificación de la Investigación

1.4.1 Por su Conveniencia

El presente estudio se justifica por la necesidad urgente de mejorar el tiempo y la precisión en el registro de las actas de audiencias del Distrito Judicial de Cusco. La transcripción manual ha demostrado ser lenta, propensa a errores y con una carga administrativa excesiva que afecta directamente la continuidad procesal y la calidad del servicio de justicia. Implementar un sistema automatizado basado en ASR resulta conveniente porque permitirá superar estas limitaciones y alinear el Poder Judicial con tendencias globales de digitalización. En experiencias internacionales, como en el Parlamento de Portugal, la adopción de sistemas de transcripción automática redujo significativamente los errores y mejoró la transparencia en los procesos legislativos (Nascimento et al., 2024).

Desde la perspectiva metodológica, la conveniencia de este trabajo radica también en su factibilidad: hace uso de herramientas ASR ya existentes y consolidadas, no requiere entrenar modelos de inteligencia artificial desde cero, y puede desplegarse sobre infraestructura disponible. Esto lo convierte en una solución práctica, replicable y pertinente para las necesidades institucionales concretas del Distrito Judicial de Cusco.

1.4.2 Por su Relevancia

La relevancia de la presente investigación reside en el impacto directo que tendrá sobre la calidad y precisión de las transcripciones de audiencias, aspecto vital para garantizar el derecho al debido proceso. En América Latina y en el Perú, son escasos los estudios empíricos que evalúen la eficacia de los sistemas ASR en contextos judiciales, lo que evidencia un vacío académico que esta investigación busca abordar. Garneau y Bolduc (2024) demostraron que ninguno de los sistemas ASR comerciales analizados alcanza la precisión requerida para prescindir de supervisión humana en entornos judiciales, lo que subraya la necesidad de evaluar estas tecnologías en contextos específicos como el judicial peruano, con sus particularidades lingüísticas y operativas.

La relevancia se fortalece además al considerar que este trabajo contribuye a resolver una problemática real con implicancias sociales y jurídicas directas: al mejorar la calidad y

celeridad de las actas, se refuerza la confianza ciudadana en el sistema de justicia y se reduce la sobrecarga del personal judicial.

1.4.3 Por sus Implicancias Prácticas

Las implicancias prácticas de esta investigación son múltiples. A corto plazo, permitirá obtener actas judiciales con mayor rapidez y con un menor número de errores, reduciendo la sobrecarga del personal judicial. A mediano y largo plazo, el modelo puede replicarse en otros distritos judiciales del país, generando un estándar tecnológico de justicia digital. Legchenko y Bondarenko (2025) comprobaron que el entrenamiento y adaptación de modelos ASR con corpus lingüísticos especializados incrementa la precisión de las transcripciones en contextos jurídicos, lo que abre la posibilidad de integrar, en el futuro, sistemas de análisis semántico y búsqueda automática de jurisprudencia.

Estas implicancias se justifican por el aporte a la transformación digital del Poder Judicial y por el beneficio directo que otorgan a jueces, secretarios, fiscales y ciudadanos que requieren procesos más céleres y confiables.

1.4.4 Por su Valor Teórico

En el plano teórico, este estudio aporta al desarrollo del conocimiento aplicado al campo de la ingeniería informática y al derecho, al demostrar cómo la integración de herramientas de inteligencia artificial puede incidir en la calidad de las transcripciones judiciales. Si bien existen investigaciones en parlamentos europeos y en cortes anglosajonas (Legchenko y Bondarenko, 2025; Garneau y Bolduc, 2024), son escasos los estudios que exploran su aplicación en el ámbito latinoamericano y, particularmente, en el Perú. Esto convierte a la investigación en un referente pionero en su contexto.

El valor teórico radica asimismo en vincular la innovación tecnológica con la garantía de derechos fundamentales: al mejorar la fidelidad de los registros procesales mediante herramientas de inteligencia artificial, se fortalece el principio de publicidad y el derecho al debido proceso.

1.4.5 Por su Valor Metodológico

La investigación tiene una utilidad metodológica relevante, pues adopta un enfoque de evaluación tecnológica basado en métricas estándar del campo ASR (WER, CER, RTF, MOS) y construye un corpus lingüístico judicial a partir de grabaciones reales del Distrito Judicial de Cusco. Este corpus y la metodología de evaluación pueden ser reutilizados en estudios posteriores, sirviendo como referencia para futuras investigaciones en contextos judiciales o administrativos del ámbito peruano.

La utilidad metodológica se justifica también porque permite garantizar la transparencia y reproducibilidad de los resultados, asegurando que la innovación propuesta pueda validarse y sostenerse en investigaciones futuras.

1.5 Delimitación del Estudio

1.5.1 Delimitación Temporal

La presente investigación comprende el periodo entre noviembre de 2025 y junio de 2026. Durante este tiempo se recopilan los datos del corpus lingüístico judicial, se realizan las observaciones institucionales, se implementa el prototipo del sistema y se evalúa su desempeño técnico. Los audios utilizados para la construcción del corpus y la evaluación comparativa provienen de grabaciones de audiencias del Distrito Judicial de Cusco realizadas entre 2024 y 2025, que sirven como base de datos para medir mejoras en precisión y tiempo de transcripción respecto al método manual. El sistema desarrollado no se limita a este periodo: una vez validado, está diseñado para operar de forma continua a futuro.

1.5.2 Delimitación Espacial

El presente estudio se llevará a cabo en el Distrito Judicial de Cusco, Perú, específicamente en las salas donde se desarrollan audiencias tanto presenciales como virtuales. Este distrito ha incrementado de manera significativa el uso de plataformas digitales en la administración de justicia tras la pandemia de COVID-19, lo que ha puesto en evidencia las limitaciones del método manual de transcripción. La elección de este distrito se justifica porque representa un contexto donde la modernización digital es urgente y donde existe un

volumen creciente de audiencias que demanda soluciones tecnológicas eficientes. Los resultados y el modelo tecnológico desarrollado podrán servir como referencia para su replicación en otros distritos judiciales del país.

CAPÍTULO 2

MARCO TEÓRICO

2.1 Antecedentes

2.1.1 Antecedentes a Nivel Internacional

Garneau y Bolduc (2024), en su estudio titulado *The State of Commercial Automatic French Legal Speech Recognition Systems and their Impact on Court Reporters*, realizado en la University of Copenhagen, se centraron en analizar el impacto de los sistemas de reconocimiento automático del habla (ASR) en el ámbito judicial canadiense y, particularmente, en el francés legal. El objetivo general fue evaluar la viabilidad de emplear ASR en la transcripción de procesos judiciales, considerando tanto su rendimiento técnico como las implicancias profesionales y legales derivadas de su implementación.

El diseño de la investigación fue experimental comparativo, basado en la evaluación de tres modelos de ASR (Amazon Transcribe, Google Speech-to-Text y OpenAI Whisper). La muestra se conformó por audios reales de carácter judicial, incluyendo grabaciones de la *Commission Charbonneau* y sentencias dictadas por jueces, con un total aproximado de 1 día, 6 horas y 37 minutos de material de audio. Como instrumentos, se utilizaron transcripciones oficiales realizadas por taquígrafos profesionales, que sirvieron como referencia para contrastar los resultados de los sistemas automáticos.

La investigación utilizó principalmente la métrica de Word Error Rate (WER) para evaluar la precisión de los modelos, considerando inserciones, eliminaciones y sustituciones. Asimismo, introdujo la Sonnex Distance, una medida fonética que permite identificar errores relacionados con homófonos, género, número y variaciones dialectales, complementando así el análisis más allá del conteo léxico.

Los hallazgos demostraron que AWS obtuvo el mejor desempeño promedio con un WER de 0,15, seguido de Google y Whisper. Sin embargo, ninguno de los sistemas alcan-

zó la precisión requerida para prescindir de supervisión humana en el ámbito judicial. En conclusión, los autores destacan que, aunque prometedores, los sistemas ASR aún deben especializarse y perfeccionarse para satisfacer las demandas críticas de exactitud en el contexto legal.

Harrington (2023), en su artículo titulado *Incorporating automatic speech recognition methods into the transcription of police-suspect interviews: factors affecting automatic performance*, publicado en la Universidad de York (Reino Unido), aborda la problemática de la baja calidad y subjetividad en las transcripciones ortográficas de entrevistas policiales entre sospechosos y autoridades judiciales. El objetivo general fue evaluar la viabilidad de integrar métodos de reconocimiento automático de voz (ASR) en el proceso de transcripción de entrevistas policiales, con la finalidad de generar registros textuales más fiables y eficientes para su utilización como evidencia en tribunales.

El diseño de la investigación fue de tipo experimental comparativo. La muestra estuvo compuesta por grabaciones extraídas de dos corpus de inglés británico forensemente relevantes: el *Dynamic Variability in Speech database* (DyViS), con 100 hablantes del sur de Inglaterra, y el *West Yorkshire Regional English Database* (WYRED), con 180 hablantes del norte de Inglaterra. Se utilizaron tres sistemas de reconocimiento automático de voz: Amazon Transcribe, Google Cloud Speech-to-Text y Rev AI.

Los resultados mostraron que Amazon Transcribe obtuvo el mejor desempeño global, con tasas de error menores al 14 % en condiciones de audio limpio, mientras que Google presentó el peor rendimiento. La autora concluye que los sistemas automáticos podrían utilizarse como un primer borrador de transcripciones, siempre que exista un proceso posterior de edición humana.

Chaloupka, Palecek y Cerva (2021), en su investigación titulada *Audio-visual broadcast transcription system using artificial neural networks*, publicada en el IEEE International Workshop on Electronics, Control, Measurement, Signals and their Application to Mechatronics, presentaron un sistema innovador para la transcripción de noticias televisivas utilizando redes neuronales artificiales. El objetivo general fue diseñar y evaluar un modelo de transcripción automática que integrara simultáneamente el procesamiento de audio y la extracción de información visual, con el fin de mejorar la precisión de las transcripciones en entornos complejos.

La muestra utilizada consistió en un corpus audiovisual de 817 horas de grabaciones de noticieros de cinco canales de televisión checos. Para la evaluación, se aplicaron métricas estándar como el Word Error Rate (WER), reduciéndolo de un 29,4 % inicial a 15,4 % tras aplicar algoritmos de corrección léxica y técnicas de preprocesamiento visual.

Los resultados evidenciaron que el sistema híbrido logró una transcripción más precisa y robusta en comparación con sistemas de audio únicamente. Los autores concluyen que este tipo de sistemas tiene un alto potencial para ser aplicado en contextos judiciales, mediáticos y administrativos.

Loakes (2024), en su artículo titulado *Automatic speech recognition and the transcription of indistinct forensic audio: how do the new generation of systems fare?*, publicado en *Frontiers in Communication*, llevó a cabo un análisis actualizado sobre el desempeño de los sistemas ASR en contextos de audio forense indistinto. Los resultados mostraron que Whisper obtuvo el mejor rendimiento en condiciones adversas, logrando transcribir el 68,9 % del material, con un WER del 50 %. Las conclusiones indicaron que la transcripción humana continúa siendo indispensable hasta que los sistemas automáticos alcancen un grado de confiabilidad superior en condiciones adversas de audio.

2.1.2 Antecedentes a Nivel Nacional

Vera (2021) desarrolló un estudio titulado *STT: Un sistema de apoyo a la transcripción de audiencias fiscales usando Vosk*, publicado en la *Revista de Investigación de Sistemas e Informática* de la Universidad Nacional Mayor de San Marcos. El objetivo general consistió en diseñar e implementar un modelo transcriptor en idioma español que permitiera agilizar el proceso de transcripción de audiencias fiscales. El desarrollo del sistema se apoyó en una arquitectura cliente-servidor utilizando VueJS para la interfaz, FastAPI para el backend, RabbitMQ y Celery como gestores de tareas asíncronas, y PostgreSQL para la gestión de datos. Los resultados mostraron que Vosk fue elegido como motor principal del sistema por su eficiencia y rapidez.

Larrea (2024), en su tesis de maestría titulada *Uso de la plataforma Google Meet y transcriptor IA en el proceso de trámite de las audiencias del módulo penal dentro del Poder Judicial de Junín en la sub sede central Huancayo 2024*, tuvo como objetivo general evaluar la influencia de la plataforma Google Meet y un transcriptor basado en inteligencia artificial

en la gestión de audiencias penales. El diseño fue cuasiexperimental de grupo único con mediciones pre y post implementación. Los resultados evidenciaron que la implementación contribuyó a una mayor celeridad en las audiencias virtuales frente a las presenciales.

Rubio Portilla (2023), en su artículo *Audiencias virtuales y su impacto en el debido proceso penal en un distrito judicial*, publicado en la revista *SCIENDO*, determinó el impacto de las audiencias virtuales en la garantía del debido proceso penal. Se aplicó la prueba estadística de Pearson, obteniendo una correlación significativa entre el uso de audiencias virtuales y el respeto del debido proceso penal ($r = 0,837$; $p < 0,05$).

En 2023, el Poder Judicial del Perú lanzó el aplicativo *Transcriptor de Audiencias Versión Alfa 2* en la Corte Superior de Justicia de Sullana, con el objetivo de disminuir la carga procesal mediante la generación casi inmediata de transcripciones al concluir las audiencias virtuales. Según reportes institucionales, el uso de la herramienta disminuyó el tiempo de elaboración en un 30 % y redujo errores manuales en un 15 % (Poder Judicial del Perú, 2023). Esta experiencia representa el antecedente práctico más cercano al problema abordado en la presente investigación y evidencia que la adopción de ASR en el sistema judicial peruano es factible, aunque aún requiere estudios académicos que documenten su funcionamiento lingüístico y su adaptabilidad a distintos contextos regionales.

2.1.3 Antecedentes a Nivel Local

Yépez-Reyes y Cruz-Silva (2024), en el artículo titulado *Inteligencia artificial en la transcripción de entrevistas*, publicado en la revista *Contratexto* (Universidad de Lima), plantearon como objetivo principal identificar la herramienta de inteligencia artificial más adecuada para la transcripción de entrevistas grabadas en español, priorizando la completitud de tareas, la eficiencia y la eficacia.

Los investigadores analizaron cuatro plataformas de IA: Office 365 (Word) Transcribe, Amazon Transcribe, Notta y Whisper (OpenAI). Los resultados demostraron que, aunque las plataformas de IA permiten transcripciones rápidas y precisas, cada una presenta ventajas y limitaciones específicas. Se concluyó que la transcripción mediante IA no sustituye completamente la revisión humana, pero sí permite optimizar tiempos y mejorar la productividad.

2.2 Marco Normativo y Operativo del Proceso de Audiencia Judicial

2.2.1 Concepto de Sistemas Automatizados en Entornos Judiciales

Los sistemas automatizados en entornos judiciales se entienden como aplicaciones tecnológicas basadas en inteligencia artificial y algoritmos de procesamiento de información, cuyo propósito es apoyar o sustituir tareas rutinarias realizadas por los operadores de justicia. Estos sistemas abarcan desde la transcripción automática de audiencias hasta la clasificación documental y la gestión de expedientes digitales. Según Cabrera Fernández (2024), la automatización judicial constituye un medio para optimizar la celeridad procesal y fortalecer la transparencia institucional, siempre que se mantenga la supervisión humana en la toma de decisiones complejas.

La incorporación de sistemas ASR en tribunales constituye un avance significativo hacia la justicia digital, aunque aún persisten limitaciones de precisión y sesgos en contextos multilingües. Loakes (2024) advierte que los sistemas automatizados enfrentan problemas de exactitud en audios de baja calidad, lo que condiciona su fiabilidad como herramientas únicas para generar registros oficiales.

2.2.2 Valor Legal de las Actas de Audiencia

Las actas de audiencia constituyen documentos públicos de carácter procesal y tienen plena validez legal en el marco de los procesos judiciales peruanos. Según el Código Procesal Civil (art. 197) y el Código Procesal Penal (art. 120), las actas constituyen prueba preconstituida y registran de manera fidedigna los actos procesales, garantizando el principio de publicidad y el derecho de defensa.

El Poder Judicial del Perú (2023) ha señalado que la digitalización de las actas, a través de grabaciones audiovisuales y su posterior transcripción, debe cumplir con estándares de autenticidad, integridad y disponibilidad, tal como exige la Ley de Gobierno Digital N.º 1412 y el Decreto Legislativo N.º 681 sobre microformas digitales con valor legal.

2.2.3 Normativa Aplicable al Uso de Sistemas Automatizados

El marco normativo vigente en el Perú ha comenzado a reconocer el uso de medios electrónicos y tecnologías emergentes en la justicia. El Reglamento de Audiencias Virtuales (R.A. 000-2020-CE-PJ) y las disposiciones del Consejo Ejecutivo del Poder Judicial regulan la conducción de audiencias virtuales, el registro audiovisual y la protección de datos personales de las partes involucradas.

Para la transcripción automatizada, se debe considerar la Ley N.º 29733 —Ley de Protección de Datos Personales—, que obliga a garantizar la privacidad de los intervinientes; la Ley de Firmas y Certificados Digitales (D.S. N.º 052-2008-PCM), que respalda el uso de firmas digitales en documentos generados electrónicamente; y la NTP 392.030-2:2015 (INACAL), que regula la producción y almacenamiento de microformas digitales con valor legal.

2.2.4 Procedimiento en una Sala de Audiencia

El desarrollo de una audiencia judicial sigue etapas formales que deben ser registradas en su integridad: instalación de la audiencia, lectura de cargos y alegatos de apertura, práctica de pruebas, alegatos de clausura y decisión del juez. Durante todo el proceso, el secretario judicial o especialista de audiencia es responsable de la redacción del acta, asegurando que los hechos y decisiones queden reflejados sin distorsiones.

2.2.5 Adaptación del Sistema ASR para Uso Judicial

La adaptación de los motores ASR al dominio judicial no requiere el reentrenamiento de los modelos base, dado que el sistema emplea servicios preentrenados (Deepgram Nova-2) que ya ofrecen alta precisión en español latinoamericano. En su lugar, la adaptación se realiza mediante tres estrategias complementarias: (a) configuración de *keyterms* jurídicos, enviando hasta 100 términos especializados a Deepgram en cada sesión de transcripción para mejorar el reconocimiento de vocabulario procesal; (b) implementación de un diccionario jurídico local con búsqueda difusa (Soundex adaptado al español y distancia de Levenshtein) para la detección y corrección postranscripción de variantes erróneas; y (c) mejoramiento lingüístico mediante Claude 3.5 Sonnet, que corrige puntuación, aplica capitalización a tér-

minos jurídicos y reemplaza palabras mal transcritas sin añadir contenido.

La evaluación del desempeño se realiza mediante métricas estándar: WER para la precisión léxica, Sonnex Distance para la similitud fonética, Real-Time Factor (RTF) para la latencia, y MOS para la calidad percibida por los operadores judiciales.

2.2.6 Aspectos de Redacción y Estilo en Actas

El lenguaje en las actas debe ser preciso, impersonal y formal. La Guía de Redacción Judicial (CNM, 2022) recomienda el uso de tercera persona y tiempo presente, estructura clara y numerada por actos procesales, e inclusión de firmas digitales o electrónicas para cerrar el documento.

2.2.7 Consideraciones Éticas y de Transparencia

El uso de IA en justicia debe regirse por principios de equidad, explicabilidad y supervisión humana (OCDE, 2023). El juez y las partes deben ser informados de que se está utilizando un sistema automatizado para transcripción y deben tener derecho a impugnar el acta si se identifican errores.

2.2.8 Inteligencia Artificial Aplicada al Reconocimiento de Voz

En los últimos años, el reconocimiento de voz ha experimentado avances significativos tanto en el ámbito académico como en el comercial. En el plano académico, Radford et al. (2022) desarrollaron el modelo *Whisper*, entrenado con aproximadamente 680 000 horas de datos multilingües y multitarea, lo cual permitió obtener un sistema robusto frente a variaciones de acento, ruido de fondo y terminología técnica. Sin embargo, *Whisper* opera exclusivamente en modo por lotes, lo que limita su aplicabilidad en escenarios que requieren transcripción en tiempo real.

En el ámbito comercial, servicios como **Deepgram Nova-2** han abordado esta limitación ofreciendo transcripción en tiempo real (*streaming*) mediante conexión WebSocket, con latencias inferiores a 300 ms y funcionalidades nativas de diarización de hablantes, indicadores de confianza por palabra y soporte para términos personalizados (*keyterms*). Estas características son fundamentales para el ámbito judicial, donde la transcripción debe reflejar

las intervenciones de múltiples participantes en tiempo real y con precisión terminológica. La elección de Deepgram Nova-2 como motor principal de transcripción en el sistema propuesto se justifica por tres razones: (1) capacidad de *streaming* nativo con baja latencia, indispensable para audiencias en vivo; (2) diarización integrada que identifica automáticamente a los hablantes; y (3) soporte de *keyterms* que permite adaptar el reconocimiento al vocabulario jurídico sin reentrenamiento del modelo.

2.2.9 Calidad en la Transcripción de Audiencias Virtuales

La calidad de las transcripciones en las audiencias judiciales virtuales se ha convertido en un eje crítico para la transparencia y eficiencia del sistema de justicia. Lyra et al. (2024) desarrollaron un sistema automatizado de transcripción que alcanzó un nivel de acierto cercano al 92 % en audios de buena calidad, lo que permitió disminuir significativamente el esfuerzo administrativo del personal.

Por su parte, Bild et al. (2021) subrayan la relevancia del componente acústico en audiencias virtuales, mostrando que una baja calidad del audio no solo afecta la fidelidad de la transcripción, sino también la percepción de credibilidad hacia los testigos.

2.3 Diseños de Sistemas de Transcripción Automática

Los avances en el diseño de sistemas de transcripción automática de audios judiciales han girado en torno a arquitecturas híbridas que combinan redes neuronales profundas, modelos ocultos de Markov y técnicas de preprocesamiento de señal.

2.3.1 Modelos de Diseño Híbrido DNN-HMM

El modelo híbrido *Deep Neural Networks – Hidden Markov Models* (DNN-HMM) ha demostrado ser una de las arquitecturas más eficaces en el campo del reconocimiento automático del habla. Este diseño integra la capacidad de representación no lineal de las redes neuronales profundas con la solidez estadística de los modelos ocultos de Markov, lo que permite capturar tanto las dependencias acústicas complejas como las transiciones temporales del habla. Chaloupka, Palecek y Cerva (2021) lo aplicaron en un sistema de transcripción audiovisual para noticias televisivas, alcanzando un desempeño superior en la reducción de

errores de palabra en comparación con sistemas basados únicamente en modelos acústicos tradicionales.

Desde el punto de vista arquitectónico, los autores implementaron una red neuronal profunda con cinco capas ocultas (1024-1024-768-768-512 neuronas) y funciones de activación ReLU, acompañada de una capa de salida con función Softmax para la clasificación de estados fonéticos. El entrenamiento se realizó en 50 épocas, integrando un vocabulario de más de 500 000 palabras y un modelo de lenguaje n-gram con suavizado Kneser-Ney.

En cuanto a métricas, la principal medida empleada fue la Word Error Rate (WER), que cuantifica errores de inserción, eliminación y sustitución. Inicialmente, los sistemas basados en DNN-HMM reportaban un WER del 29,4 %, pero mediante la incorporación de información visual y estrategias de preprocesamiento los investigadores lograron reducirlo hasta un 15,4 %.

Cuadro 2.1: Arquitectura del modelo híbrido DNN-HMM

Componente	Descripción	Detalles técnicos
Entradas	Características acústicas	MFCC, 44.1 kHz, 16 bits
Red DNN	5 capas ocultas	1024-1024-768-768-512 neuronas, ReLU
Capa de salida	Clasificación de estados fonéticos	Softmax
Modelo de lenguaje	N-gram	Suavizado Kneser-Ney, 500k palabras
Entrenamiento	Iteraciones	50 épocas
Métricas	Precisión	WER reducido de 29,4 % a 15,4 %

2.3.2 Modelos ASR Multilingües y Servicios Comerciales

El campo del reconocimiento automático del habla ha sido transformado tanto por modelos académicos de código abierto como por servicios comerciales basados en la nube. Entre los modelos académicos, Radford et al. (2022) destacan que Whisper logra generalizar de manera efectiva en condiciones no vistas durante el entrenamiento, superando a modelos DNN-HMM tradicionales. En el ámbito comercial, servicios como Deepgram Nova-2 ofrecen transcripción en tiempo real (*streaming*) con latencias inferiores a 300 ms y funcio-

nalidades nativas de diarización, lo que los hace especialmente adecuados para aplicaciones judiciales en vivo donde la inmediatez es crítica.

Cuadro 2.2: Comparación de modelos ASR multilingües y comerciales

Modelo	Diseño / Arquitectura	Idiomas Soportados	Características Relevantes
Deepgram Nova-2	Modelo propietario basado en <i>deep learning</i> , optimizado para <i>streaming</i> en tiempo real	+30 idiomas (incl. es-419)	Diarización nativa, <i>keyterms</i> , confianza por palabra, baja latencia (< 300 ms). Motor utilizado en el sistema propuesto.
Whisper (OpenAI)	Codificador-Decodificador Transformer con autoatención multinivel	+90 idiomas	Entrenamiento multitarea (traducción + transcripción); robustez en ruido y acentos
Wav2Vec 2.0 (Meta)	Modelo auto-supervisado basado en Transformers	53 idiomas	Preentrenamiento sin etiquetas + ajuste fino en corpus de voz etiquetado
SpeechT5 (Microsoft)	Transformer multimodal con soporte para síntesis y reconocimiento	Multilingüe	Capacidad de convertir texto a voz y viceversa en un mismo modelo

Cuadro 2.3: Métricas de desempeño de modelos ASR

Modelo	WER en Audio Limpio	WER en Audio con Ruido	Latencia Promedio
Deepgram Nova-2	8,4 % (español, benchmark interno)	~20 % en ruido moderado	< 300 ms en <i>streaming</i>
Whisper (Large)	2,7 % (LibriSpeech)	50 % (audio forense, Loakes, 2024)	Solo procesamiento por lotes (sin <i>streaming</i> nativo)
Wav2Vec 2.0 Base	5,2 % (LibriSpeech)	58 % en ruido simulado	< 2 s en inferencia sin conexión
SpeechT5	4,8 % (VoxPopuli)	55 % en ruido moderado	2,5 s promedio

Cuadro 2.4: Parámetros y estrategias de entrenamiento

Modelo	Tamaño de Pa- rámetros	Datos de Entrena- miento	Estrategias de Op- timización
Whisper	1,5B – 1,55B	680 000 h de audio multilingüe	Aprendizaje multitarea, <i>data augmentation</i> con ruido
Wav2Vec 2.0	95M – 317M	53 idiomas (VoxPopuli)	Preentrenamiento auto-supervisado, ajuste fino supervisado
SpeechT5	280M	Multimodal (texto + voz)	<i>Transfer learning</i> y ajuste fino en tareas específicas

Cuadro 2.5: Validación y tipos de error evaluados

Modelo	Tipos de Error Medidos	Herramientas de Evaluación	Resultados Clave
Deepgram Nova-2	Inserciones, sustituciones, omisiones, errores de diarización	WER, confianza por palabra	Alta precisión en <i>streaming</i> ; diarización nativa con identificación de hablante
Whisper	Inserciones, sustituciones, omisiones	WER, BLEU para traducción	Alta precisión en entornos controlados, disminuye en audio forense
Wav2Vec 2.0	Errores fonéticos y semánticos	WER, Character Error Rate (CER)	Mejor rendimiento en entornos de bajo ruido
SpeechT5	Errores de prosodia y segmentación	MOS (Mean Opinion Score), WER	Buen balance entre naturalidad y exactitud

2.3.3 Modelos Cliente-Servidor y Arquitecturas Distribuidas

Los modelos cliente-servidor constituyen uno de los pilares fundamentales en el diseño de sistemas de transcripción automatizada de audiencias, ya que permiten distribuir las cargas de procesamiento de manera eficiente entre los nodos de entrada (clientes) y los nodos de procesamiento central (servidores). En el contexto de sistemas ASR judiciales, el cliente captura el audio en tiempo real, lo envía mediante protocolos de transmisión de baja latencia

(como WebRTC o WebSockets) y el servidor procesa los datos con motores de reconocimiento de voz basados en inteligencia artificial. Esta arquitectura asegura que el procesamiento intensivo de cómputo se realice en el *backend*, reduciendo la carga de los dispositivos de captura y garantizando escalabilidad (Kasakowskij, 2025).

La arquitectura distribuida se convierte en un complemento natural del modelo cliente-servidor al permitir que múltiples servidores trabajen en paralelo en tareas de preprocesamiento de audio, segmentación de hablantes y transcripción. Vera (2021) utilizó un esquema basado en FastAPI como *backend* y RabbitMQ/Celery como gestores de colas de tareas, lo que permitió procesar audios de manera asíncrona y mejorar la capacidad de respuesta del sistema.

Cuadro 2.6: Componentes clave en modelos cliente-servidor y arquitecturas distribuidas para sistemas ASR judiciales

Componente	Descripción	Herramientas	Beneficio Principal
Cliente	Captura de audio y envío al servidor en tiempo real	WebRTC, WebSockets	Baja latencia y sincronización en vivo
Servidor de Aplicación	Procesa el audio recibido, gestiona colas y coordina tareas	FastAPI, Celery, Redis	Escalabilidad y procesamiento asíncrono
Motor de ASR	Realiza la transcripción automática utilizando modelos IA	Deepgram Nova-2 (<i>streaming</i> y <i>lotes</i>)	Alta precisión en reconocimiento de voz con diarización integrada
Balanceador de Carga	Distribuye solicitudes entre múltiples nodos de servidor	NGINX, Kubernetes Ingress	Reducción de cuellos de botella
Seguridad y Privacidad	Protege la información sensible transmitida y almacenada	TLS 1.3, JWT, OAuth 2.0	Confidencialidad e integridad de datos

2.3.4 Modelos Multimodales y Fusión de Señales

Los modelos multimodales han surgido como una alternativa avanzada para mejorar la precisión de los sistemas de transcripción en entornos judiciales. Estos modelos combinan diferentes tipos de datos —audio, video y texto— para generar representaciones más robustas y completas. Chaloupka, Palecek y Cerva (2021) demostraron que la integración de

información visual junto con las señales acústicas mejora la segmentación de turnos de habla y reduce errores en entornos de ruido.

El enfoque multimodal puede implementarse mediante diferentes técnicas de fusión: temprana (*early fusion*), tardía (*late fusion*) e híbrida. Baltrušaitis et al. (2019) han demostrado que la fusión temprana es más eficaz en tareas que requieren correlación directa entre modalidades, mientras que la fusión tardía es más robusta frente a la pérdida de datos en alguna de las fuentes de señal.

Cuadro 2.7: Tipos de fusión de señales en modelos multimodales para ASR judicial

Tipo de Fusión	Descripción Técnica	Ventajas	Limitaciones	Aplicación en Justicia
Fusión Temprana	Combina señales en la etapa de entrada	Mayor correlación entre modalidades	Requiere datos completos de todas las modalidades	Transcripción en audiencias con video de alta calidad
Fusión Tardía	Procesa cada modalidad de forma independiente	Robusta frente a pérdida de datos	Puede perder relaciones temporales finas	Audiencias con video parcial o señal de baja calidad
Fusión Híbrida	Combina fusión temprana y tardía	Balance entre robustez y correlación temporal	Complejidad computacional elevada	Sistemas judiciales de alta exigencia
Fusión Contextual	Integra metadatos y contexto legal	Enriquece el resultado con información semántica	Requiere bases de datos bien estructuradas	Generación automática de actas con identificación de intervinientes

2.4 Métricas y Parámetros de Evaluación

La evaluación de sistemas de reconocimiento automático del habla en contextos judiciales exige el uso de métricas robustas que permitan medir no solo la precisión de las transcripciones, sino también su utilidad práctica en la producción de actas oficiales. Entre las métricas más empleadas se encuentra el Word Error Rate (WER), que cuantifica los errores de sustitución, inserción y omisión en relación con el número total de palabras de referencia:

$$\text{WER} = \frac{S + D + I}{N} \times 100$$

(2.1)

donde S representa sustituciones, D eliminaciones, I inserciones y N el número total de palabras de referencia (Garneau y Bolduc, 2024).

Cuadro 2.8: Métricas y parámetros de evaluación en sistemas ASR judiciales

Métrica / Parámetro	Definición	Método	Aplicación Judicial
Word Error Rate (WER)	Porcentaje de errores de palabras respecto al total de referencia	$(S + D + I)/N \times 100$	Medición de precisión general de la transcripción
Character Error Rate (CER)	Porcentaje de errores a nivel de caracteres	Similar a WER pero a nivel de caracteres	Útil para lenguas con alta complejidad morfológica
BLEU Score	Evalúa correspondencia entre texto generado y referencia	Cálculo basado en n-gramas coincidentes	Útil en traducción automática de audiencias multilingües
MOS (Mean Opinion Score)	Medida subjetiva de calidad percibida	Escala de 1 a 5 evaluada por expertos	Validación de inteligibilidad y naturalidad en actas
Latencia (ms)	Tiempo promedio de procesamiento por unidad de audio	Medición en pruebas de estrés	Determina viabilidad para audiencias en tiempo real
Uso de GPU/CPU	Consumo de recursos computacionales	Monitoreo en entornos de prueba	Requisito para estimar costos y escalabilidad

2.4.1 Word Error Rate (WER) y Sonnex Distance

La Word Error Rate (WER) es la métrica de referencia más utilizada en la evaluación de sistemas ASR, ya que permite cuantificar de manera objetiva el nivel de coincidencia entre la transcripción automática y la transcripción de referencia (*ground truth*). Su fórmula estándar es:

$$\text{WER} = \frac{S + D + I}{N} \times 100$$

(2.2)

Un valor de WER del 0 % indica una transcripción perfecta, mientras que valores superiores al 30 % suelen considerarse inaceptables en contextos críticos como el judicial (Harrington, 2023). En investigaciones recientes se reportan WER promedios del 15 % para sistemas como Amazon Transcribe y del 18 % para Whisper en condiciones de audio limpio, pero estos valores se incrementan hasta 50 % en audios forenses con ruido de fondo (Loakes, 2024). En contraste, servicios comerciales optimizados para *streaming* como Deepgram Nova-2 reportan WER de aproximadamente 8,4 % en español en condiciones estándar, con la ventaja adicional de operar en tiempo real con latencias inferiores a 300 ms.

A diferencia del WER, que se limita a medir coincidencias léxicas, la **Sonnex Distance** es una métrica de carácter fonético que compara la similitud de las secuencias de sonido entre el texto de referencia y la transcripción automática. Este enfoque permite identificar errores que no son necesariamente léxicos, como variaciones de género, número o errores en homófonos (Garneau y Bolduc, 2024).

Cuadro 2.9: Métricas de evaluación léxica y fonética en sistemas ASR

Métrica	Aspecto Evaluado	Fórmula / Método	Aplicación Judicial
WER	Coincidencia léxica de palabras	$(S + D + I)/N \times 100$	Detecta errores de sustitución, inserción y omisión en actas de audiencia
Sonnex Distance	Similitud fonética	Distancia de edición fonética ponderada	Identifica errores de homófonos, género y número; útil en entornos multilingües

2.4.2 Métricas de Latencia y Tiempo de Procesamiento

En los sistemas ASR, la latencia y el tiempo de procesamiento son métricas críticas que determinan la viabilidad de su uso en entornos de tiempo real. La latencia se define como el intervalo de tiempo que transcurre entre la entrada de la señal de audio y la generación de la transcripción correspondiente (Macháček et al., 2023). Su cálculo es:

Latencia (ms) = $t_{\text{salida}} - t_{\text{entrada}}$

(2.3)

El tiempo de procesamiento puede expresarse mediante el Real-Time Factor (RTF):

$$\text{RTF} = \frac{t_{\text{procesamiento}}}{t_{\text{audio}}} \quad (2.4)$$

Un valor de $\text{RTF} < 1$ indica que el sistema es más rápido que el tiempo real, lo cual es deseable para aplicaciones de audiencias virtuales.

Cuadro 2.10: Métricas de evaluación de desempeño en sistemas ASR

Métrica	Definición	Parámetro Clave	Valor Óptimo para Audiencias
Latencia	Tiempo entre la captura del audio y la salida de la transcripción	$t_{\text{salida}} - t_{\text{entrada}}$	$< 300 \text{ ms}$
Tiempo de Procesamiento (RTF)	Proporción entre tiempo de cómputo y duración del audio procesado	$t_{\text{procesamiento}}/t_{\text{audio}}$	$< 1,0$
Throughput	Volumen de datos procesados por unidad de tiempo	Palabras/s o frases/s	$\geq 150 \text{ wpm}$

2.4.3 Parámetros Acústicos y de Entrenamiento

El desempeño de un sistema ASR depende en gran medida de la correcta selección de parámetros acústicos y de la estrategia de entrenamiento aplicada al modelo. Los parámetros acústicos más comunes son los coeficientes cepstrales en las frecuencias de Mel (MFCCs), los filtros log-Mel y los espectrogramas de potencia (Gulati et al., 2020). La extracción de parámetros MFCC se resume en la siguiente secuencia matemática:

$$c_n = \text{DCT} \left[\log \left(M \cdot |FFT(x(t) \cdot w(t))|^2 \right) \right] \quad (2.5)$$

donde $x(t)$ es la señal de entrada, $w(t)$ es la ventana de análisis (ventana Hamming de 25 ms), FFT es la Transformada Rápida de Fourier, M es el banco de filtros de Mel y DCT es la Transformada Discreta del Coseno.

Cuadro 2.11: Parámetros acústicos y de entrenamiento en modelos ASR

Categoría	Parámetro	Valor Típico	Importancia en el Modelo
Acústicos	Tamaño de ventana (frame)	25 ms (solapamiento 10 ms)	Determina la resolución temporal del análisis espectral
	Número de filtros Mel	40 filtros	Captura de energía en bandas de frecuencia perceptual
	Coeficientes MFCC	13-39 coeficientes	Representación compacta de la envolvente espectral
Entrenamiento	Dataset de entrenamiento	>10 000 h de audio	Mejora la capacidad de generalización
	Tasa de aprendizaje	1e-4 a 1e-3	Controla la convergencia de la red neuronal
	Tamaño del batch	16-64 ejemplos por iteración	Impacta en estabilidad y tiempo de entrenamiento
	Épocas de entrenamiento	50-200	Define la cantidad de iteraciones sobre el dataset

2.4.4 Validación Estadística

La validación estadística constituye un componente esencial en el desarrollo de sistemas ASR, ya que garantiza que los resultados obtenidos no sean producto del azar. Un enfoque común es el uso de pruebas t para muestras relacionadas, cuando se cuenta con pares de resultados antes y después de implementar el sistema:

$$t = \frac{\bar{d}}{s_d/\sqrt{n}} \quad (2.6)$$

donde $\bar{d}$ es la media de las diferencias entre pares, s_d es la desviación estándar de las diferencias y n es el número de pares de observaciones. Si el valor de $p < 0,05$, se rechaza la hipótesis nula.

En investigaciones con varias condiciones experimentales, se utiliza el Análisis de

Varianza (ANOVA):

$$F = \frac{MS_{\text{entre}}}{MS_{\text{dentro}}} \quad (2.7)$$

donde MS_{entre} representa la variación media entre grupos y MS_{dentro} la variación media dentro de cada grupo. En contextos donde no se cumplen supuestos de normalidad, se emplean métodos no paramétricos como la prueba de Wilcoxon para muestras emparejadas o la prueba de Kruskal-Wallis para comparaciones de múltiples grupos (Larrea, 2024).

2.5 Desarrollo del Proyecto

El desarrollo del presente proyecto se orienta a la implementación de un sistema automatizado de transcripción de audiencias judiciales basado en inteligencia artificial, cuyo propósito es mejorar la precisión y reducir los tiempos de producción de actas judiciales en el Distrito Judicial de Cusco. El sistema hace uso de herramientas de inteligencia artificial ya existentes y consolidadas: **Deepgram Nova-2** para el reconocimiento automático del habla en tiempo real y **Claude 3.5 Sonnet** (Anthropic, modelo `claude-3-5-sonnet-20241022`) para el mejoramiento lingüístico del texto y la generación de actas con formato oficial. No se desarrolla ni entrena un modelo de IA propio; el aporte del sistema radica en la integración, adaptación y evaluación de estas herramientas en el contexto del Distrito Judicial de Cusco, utilizando un corpus lingüístico judicial construido a partir de grabaciones reales.

El sistema se estructura en dos etapas de implementación: la primera etapa entrega un producto mínimo viable (MVP) con transcripción en tiempo real, detección de múltiples hablantes, edición asistida y generación de actas; la segunda etapa incorpora mejoras de precisión, procesamiento por lotes, flujo de aprobación de actas y exportación documental en formatos DOCX y PDF.

2.5.1 Arquitectura de Software

La arquitectura de software ha sido diseñada bajo un modelo cliente-servidor distribuido, asegurando la interoperabilidad de los componentes y la posibilidad de integrarse con los sistemas de gestión documental existentes en el Poder Judicial. El sistema se compone

de seis servicios principales orquestados mediante Docker Compose y desplegados sobre un servidor de producción VPS KVM 2 de Hostinger, el cual cuenta con un dominio web configurado para el consumo real de las APIs institucionales. Estos servicios son: (1) frontend Next.js 14; (2) backend FastAPI; (3) PostgreSQL 16; (4) Redis; (5) Celery worker; y (6) nginx como proxy inverso que gestiona de manera segura el tráfico de red en producción.

2.5.2 Stack Tecnológico

Cuadro 2.12: Stack tecnológico del sistema

Capa	Tecnología	Justificación
Frontend	Next.js 14	Framework React con App Router y renderizado del lado del servidor
	TypeScript	Tipado estático para reducir errores en desarrollo
	TipTap (ProseMirror)	Editor extensible para el canvas de transcripción
	Zustand	Gestor de estado ligero y reactivo
	wavesurfer.js	Reproductor de audio con forma de onda sincronizado
Backend	FastAPI	Framework web asíncrono con documentación OpenAPI automática
	SQLAlchemy async + asyncpg	ORM asíncrono con driver nativo para PostgreSQL
	Alembic	Gestión de migraciones de base de datos
	Celery + Redis	Cola de tareas para procesamiento por lotes
Base de datos	PostgreSQL 16	Base de datos relacional con soporte JSONB
APIs Externas	Deepgram Nova-2	ASR en tiempo real con diarización nativa (<i>streaming</i>)
	Claude 3.5 Sonnet (Anthropic)	Mejoramiento lingüístico y generación de actas
Proc. por lotes	Deepgram Pre-recorded API	ASR por lotes con diarización integrada (<i>diarize=true</i>), sin dependencia de GPU
Infraestructura	VPS KVM 2 de Hostinger + Docker	Orquestación de servicios y despliegue real en producción con dominio y proxy inverso
Exportación	python-docx / xhtml2pdf (pisa)	Generación de DOCX y PDF con formato oficial

2.5.3 Servicios Externos de Inteligencia Artificial

El sistema utiliza exclusivamente dos servicios externos de inteligencia artificial:

1. **Deepgram Nova-2:** Servicio ASR basado en la nube que ofrece transcripción en tiempo real mediante conexión WebSocket (SDK oficial `deepgram-sdk`). Se configura con idioma español latinoamericano (`es-419`), diarización activada (`diarize=true`), formato inteligente (`smart_format=true`), *endpointing* en 500 ms y hasta 100 *keyterms* jurídicos por sesión.
2. **Claude 3.5 Sonnet (Anthropic, `claude-3-5-sonnet-20241022`):** Modelo de lenguaje utilizado para: (a) el mejoramiento del texto transcrito —corrección de puntuación, capitalización de términos jurídicos, sin añadir palabras no pronunciadas—; y (b) la generación del acta judicial formal a partir del contenido del canvas y los metadatos de la audiencia.

Todos los demás componentes —diccionario jurídico, procesamiento de audio, editor de texto, base de datos, exportación documental, procesamiento por lotes— operan localmente sin depender de servicios externos adicionales.

2.5.4 Corpus Lingüístico Judicial

Para la evaluación del sistema se construirá un corpus lingüístico judicial a partir de grabaciones reales de audiencias del Distrito Judicial de Cusco, previa autorización institucional y bajo las disposiciones de la Ley N.º 29733 —Ley de Protección de Datos Personales—. El corpus incluirá grabaciones de audiencias presenciales y virtuales de distintas especialidades (penal, laboral, familia), con una duración mínima de 20 minutos por audiencia y participación de al menos dos interlocutores. Las transcripciones de referencia (*ground truth*) serán elaboradas por personal judicial capacitado, garantizando la fidelidad del texto respecto al audio original. Este corpus constituye el insumo central para calcular las métricas WER, CER y RTF del sistema en condiciones reales.

2.5.5 Interfaz de Usuario

El frontend es una aplicación web desarrollada con Next.js 14 y React 18 en TypeScript, que comprende los siguientes componentes principales: canvas de transcripción con editor TipTap personalizado, panel de hablantes con 15 roles procesales disponibles, reproductor de audio sincronizado con timestamps, panel de marcadores y sugerencias del dic-

cionario jurídico, editor de acta con estructura oficial del Poder Judicial, y panel de revisión para el procesamiento por lotes.

2.5.6 Captura y Almacenamiento de Audio

La captura de audio se realiza en el navegador mediante la Web Audio API a 16 kHz mono, con fragmentos cada 250 ms enviados por WebSocket al backend. En el servidor, un módulo de grabación abre un archivo WAV (16 bit, 16 kHz, mono) por audiencia. Al finalizar la sesión, el archivo WAV se cierra y se actualiza la ruta y duración en la base de datos, garantizando la preservación del registro sonoro para consulta posterior y procesamiento por lotes.

2.5.7 Módulo de Transcripción en Tiempo Real

El flujo de transcripción sigue la secuencia: el frontend envía fragmentos de audio cada 250 ms por WebSocket; el backend los reenvía a Deepgram Nova-2 y recibe resultados con identificador de hablante, confianza por palabra y marcas de tiempo; el servicio de consolidación agrupa segmentos del mismo hablante hasta formar frases completas; el segmento consolidado se envía a Claude 3.5 Sonnet para mejoramiento y al diccionario jurídico; y el segmento final se persiste en PostgreSQL y se envía al canvas del operador.

2.5.8 Módulo del Diccionario Jurídico

El diccionario jurídico opera localmente sin dependencia de servicios externos. Emplea Soundex adaptado al español y distancia de Levenshtein para búsqueda difusa. Se configuran hasta 100 *keyterms* jurídicos por sesión en Deepgram, organizados por categorías: procesal penal, delitos, partes procesales, normativa y terminología regional de Cusco.

2.5.9 Módulo de Generación de Actas

El sistema captura un resumen del canvas y los metadatos de la audiencia (expediente, juzgado, tipo, fecha, hablantes con roles). El contenido se envía a Claude 3.5 Sonnet con un formato de instrucciones específico para el formato oficial del Poder Judicial del Perú. El

acta pasa por un flujo de aprobación: borrador, en revisión y aprobada, requiriéndose el rol de supervisor para la aprobación final.

2.5.10 Módulo de Exportación Documental

La exportación genera documentos DOCX mediante python-docx con plantilla de estilos oficiales, y PDF mediante xhtml2pdf (pisa). Cada exportación se registra en la tabla de auditoría con el identificador del usuario, formato y fecha.

2.5.11 Modelo de Datos

Cuadro 2.13: Entidades principales del modelo de datos

Entidad	Campos clave	Descripción
Audiencia	expediente, juzgado, tipo_audiencia, instancia, fecha, estado, audio_path	Sesión judicial con metadatos completos y referencia de sesión Deepgram
Segmento	audiencia_id, speaker_id, texto_ia, texto_mejorado, texto_editado, texto_batch, timestamps, confianza, orden, editado_por_usuario	Unidad de transcripción con trazabilidad completa
Hablante	audiencia_id, speaker_id, rol, etiqueta, nombre, color	Rol procesal de cada hablante; hasta 15 roles disponibles
Marcador	audiencia_id, usuario_id, nota, timestamp, tipo	Punto de interés con nota y categoría del operador
Acta	audiencia_id, contenido_llm, contenido_editado, version, formato, estado, aprobada_por	Acta con historial, formato y flujo de aprobación
AuditLog	accion, entidad_tipo, entidad_id, usuario_id, detalles	Registro de acciones críticas del sistema
Usuario	email, nombre, rol, password_hash, activo	Roles: administrador, transcriptor, supervisor

2.5.12 Seguridad del Sistema

La autenticación se implementa mediante JWT con *access token* y *refresh token*. Las contraseñas se almacenan con hashing bcrypt (12 rondas). Solo el texto se envía a Claude, nunca el audio. El transporte se asegura mediante HTTPS con nginx como terminación TLS en producción.

2.5.13 Metodología de Desarrollo de Software

El desarrollo sigue un enfoque ágil basado en Scrum, con iteraciones cortas que concluyen con la entrega de un incremento potencialmente desplegable. Las funcionalidades se priorizan según la técnica MoSCoW (Must, Should, Could, Won't) y se validan mediante demostraciones periódicas con los usuarios del Distrito Judicial.

2.6 Marco Conceptual

El marco conceptual constituye la base semántica y teórica de la presente investigación, ya que precisa y define los términos técnicos, jurídicos y tecnológicos utilizados a lo largo del trabajo.

2.6.1 Inteligencia Artificial (IA)

La inteligencia artificial (IA) es un campo de la informática que busca desarrollar sistemas capaces de realizar tareas que normalmente requieren inteligencia humana, tales como el aprendizaje, el razonamiento, la planificación y el reconocimiento de patrones. La IA se divide en ramas como el aprendizaje automático (*machine learning*) y el aprendizaje profundo (*deep learning*), que permiten a los modelos mejorar su rendimiento a medida que se exponen a nuevos datos (Russell y Norvig, 2024).

En el contexto de esta investigación, la IA es el núcleo de la solución tecnológica, ya que habilita el reconocimiento de voz en tiempo real mediante Deepgram Nova-2 y el mejoramiento lingüístico y generación de actas mediante Claude 3.5 Sonnet. Es importante precisar que el sistema no desarrolla ni entrena modelos propios de IA, sino que integra y adapta herramientas ya existentes al contexto judicial cusqueño.

2.6.2 Reconocimiento Automático del Habla

El reconocimiento automático del habla (ASR) es una tecnología que convierte señales acústicas en texto mediante la combinación de modelos acústicos, modelos de lenguaje y algoritmos de decodificación. Este proceso suele involucrar la extracción de características como los coeficientes cepstrales en la frecuencia de Mel (MFCC), que sirven como insumo para redes neuronales profundas o arquitecturas híbridas DNN-HMM (Chaloupka et al., 2021). Para la presente investigación, el ASR constituye la piedra angular del sistema propuesto, pues sustituye la transcripción manual de audiencias, reduciendo tiempos y carga administrativa.

2.6.3 Transcripción Judicial

La transcripción judicial es el procedimiento que convierte en texto escrito las declaraciones orales, intervenciones y decisiones emitidas en una audiencia (Poder Judicial del Perú, 2023). Esta actividad es fundamental para garantizar el derecho al debido proceso, ya que el acta de audiencia se constituye en un documento oficial que respalda las actuaciones judiciales. En el Distrito Judicial de Cusco, la transcripción se realiza manualmente, lo que incrementa el riesgo de errores humanos y demora la disponibilidad de actas.

2.6.4 Celeridad Procesal

La celeridad procesal es un principio rector de la justicia que busca que los procesos se desarrollen en un plazo razonable y sin dilaciones indebidas. Este principio se encuentra consagrado en la Constitución Política del Perú y en tratados internacionales, como la Convención Americana sobre Derechos Humanos. La implementación de sistemas de transcripción automática contribuye directamente a este principio al reducir el tiempo de entrega de actas y resoluciones. Prescott (2020) sostiene que el uso de tecnologías de información en los tribunales es un catalizador para fortalecer la confianza ciudadana, siempre que se garantice la imparcialidad y se mantenga la integridad de los registros procesales.

2.6.5 Eficiencia Institucional

La eficiencia institucional se define como la capacidad de una organización para alcanzar sus objetivos con el mínimo de recursos, maximizando su productividad y efectividad. En el Poder Judicial, esta eficiencia se relaciona con la reducción de la sobrecarga administrativa y la agilización de procesos críticos como la transcripción de audiencias. La automatización de las transcripciones libera a los especialistas de tareas repetitivas, lo que incrementa la productividad institucional (Bauer et al., 2025).

2.6.6 FastAPI

FastAPI es un framework web moderno de Python, diseñado para construir APIs de alto rendimiento con tipado estático y generación automática de documentación OpenAPI. Se ejecuta sobre servidores ASGI como Uvicorn, lo que le permite gestionar operaciones de entrada/salida de forma asíncrona y atender conexiones concurrentes sin sacrificar rendimiento. En el sistema propuesto, FastAPI se emplea como el servidor backend que coordina la autenticación JWT, la gestión de audiencias, la persistencia en PostgreSQL mediante SQLAlchemy asíncrono, la ejecución de tareas diferidas con Celery y Redis, y la comunicación en tiempo real con el frontend.

2.6.7 WebSocket

WebSocket es un protocolo que establece un canal de comunicación bidireccional persistente entre cliente y servidor, reduciendo la latencia en el intercambio de datos (Fette y Melnikov, 2011). Esta característica es crucial en entornos judiciales, donde la inmediatez en la transcripción de declaraciones puede incidir en la toma de decisiones.

2.6.8 Deepgram

Deepgram es un servicio de reconocimiento automático del habla basado en la nube que ofrece transcripción en tiempo real y por lotes mediante modelos de inteligencia artificial propietarios. Su familia de modelos Nova proporciona alta precisión en múltiples idiomas, incluyendo español latinoamericano (`es-419`), con soporte nativo para detección de hablantes (*diarization*), puntuación automática, indicadores de confianza por palabra y

personalización mediante *keyterms*. En el sistema propuesto se utiliza el modelo **Nova-2** tanto para el *streaming* en tiempo real como para el procesamiento por lotes mediante su API Pre-recorded.

2.6.9 Next.js

Next.js es un framework de React para el desarrollo de aplicaciones web, que ofrece renderizado del lado del servidor, generación estática y enrutamiento basado en el sistema de archivos. En el sistema propuesto, Next.js 14 se utiliza como la plataforma del frontend, proporcionando una interfaz web completa que incluye el panel de audiencias, el canvas de transcripción, la gestión de hablantes y la edición de actas.

2.6.10 Whisper y faster-whisper

Whisper es un modelo de ASR desarrollado por OpenAI, entrenado con 680 000 horas de datos de audio multilingües. Su diseño basado en transformadores lo hace robusto frente a ruido de fondo, acentos y terminología especializada (Radford et al., 2022). Estos modelos constituyen una referencia importante en la literatura ASR y en el marco teórico de esta investigación como alternativa de procesamiento de alta precisión. En la implementación actual del sistema, el procesamiento por lotes se realiza mediante la API Pre-recorded de Deepgram, que incluye diarización integrada sin requerir GPU local, simplificando la infraestructura de despliegue.

2.6.11 Word Error Rate (WER)

El WER es la métrica estándar para evaluar la precisión de los sistemas ASR. Se calcula mediante la fórmula:

$$\text{WER} = \frac{S + D + I}{N} \times 100 \quad (2.8)$$

donde S representa sustituciones, D eliminaciones, I inserciones y N el total de palabras de referencia (Morris et al., 2004). Un valor inferior al 10 % es aceptable en aplicaciones de alta exigencia, como la transcripción judicial (Garneau y Bolduc, 2024). Esta

métrica será utilizada en la investigación para medir objetivamente el impacto del sistema propuesto.

2.6.12 Claude (Anthropic)

Claude es un modelo de lenguaje de gran escala desarrollado por Anthropic, diseñado para tareas de comprensión, generación y análisis de texto. En el sistema propuesto se utiliza **Claude 3.5 Sonnet** (identificador de la API: `claude-3-5-sonnet-20241022`), que cumple dos funciones: (a) el mejoramiento lingüístico de los segmentos transcritos — corrección de puntuación, capitalización de términos jurídicos, reemplazo ortográfico sin añadir palabras—; y (b) la generación del acta judicial formal a partir del contenido del canvas y los metadatos de la audiencia. A diferencia de los modelos de reconocimiento de voz, Claude opera exclusivamente sobre texto.

2.6.13 TipTap

TipTap es un framework de edición de texto enriquecido para aplicaciones web, construido sobre ProseMirror. Permite crear editores altamente personalizables mediante un sistema de extensiones modulares. En el sistema propuesto, TipTap se utiliza para implementar el canvas de transcripción con extensiones personalizadas: nodos de hablante con etiquetas y colores, marcas de segmento con marcas de tiempo, indicadores de baja confianza y marcadores de revisión.

2.6.14 PostgreSQL

PostgreSQL es un sistema de gestión de bases de datos relacional de código abierto, reconocido por su robustez y cumplimiento de estándares SQL. En su versión 16, incorpora soporte nativo para datos semiestructurados mediante el tipo JSONB, lo que permite almacenar información flexible como las palabras individuales con marcas de tiempo y confianza de cada segmento de transcripción.

2.6.15 Docker

Docker es una plataforma de virtualización a nivel de contenedores que permite empaquetar aplicaciones con todas sus dependencias en unidades aisladas y reproducibles. En el sistema propuesto, Docker Compose orquesta seis servicios: frontend (Next.js), backend (FastAPI), PostgreSQL, Redis, Celery worker y nginx, asegurando un despliegue reproducible en cualquier entorno servidor.

2.6.16 Redis

Redis es un almacén de datos en memoria de código abierto, utilizado como base de datos, caché y broker de mensajes. En el sistema propuesto, Redis actúa como broker de mensajes para Celery, gestionando las colas de tareas del procesamiento por lotes. Su naturaleza en memoria permite una comunicación de baja latencia entre el backend y los workers de procesamiento.

CAPÍTULO 3

METODOLOGÍA

3.1 Metodología de Investigación

La metodología constituye el eje central de la investigación, pues permite organizar y ejecutar de manera sistemática las fases del proyecto, garantizando la validez y reproducibilidad de los resultados obtenidos. En el caso del presente trabajo, se busca diseñar, implementar y evaluar un sistema automatizado de transcripción de audiencias judiciales empleando inteligencia artificial —específicamente mediante la integración de Deepgram Nova-2 para el reconocimiento automático del habla en tiempo real y Claude 3.5 Sonnet para el mejoramiento lingüístico y la generación de actas judiciales—. La metodología se fundamenta en el enfoque de investigación aplicada de desarrollo tecnológico, centrada en la construcción, prueba y validación de un prototipo funcional orientado a mejorar la precisión y eficiencia de la transcripción judicial en el Distrito Judicial de Cusco. Para asegurar el rigor operativo, todas las pruebas y la recolección de métricas se ejecutan proyectando el sistema sobre una infraestructura real de producción bajo un servidor VPS KVM 2 de Hostinger empleando un dominio web propio, prescindiendo por completo de entornos locales de desarrollo simulado y garantizando el consumo de las APIs con datos reales.

El proceso metodológico se estructura en los siguientes apartados: tipo y alcance de investigación, método y diseño, enfoque, corpus y unidad de análisis, técnicas de recolección, métricas de evaluación y metodología de desarrollo de software. El desarrollo del sistema sigue un enfoque ágil, que permite la integración iterativa de componentes tecnológicos, la validación temprana de resultados y la mejora continua durante las fases de diseño y evaluación.

3.2 Tipo y Alcance de Investigación

3.2.1 Tipo de Investigación

La investigación es de tipo aplicada y de desarrollo tecnológico, dado que busca generar una solución informática para un problema real del sistema judicial: la transcripción manual de audiencias que genera demoras, errores y sobrecarga administrativa. La investigación aplicada se caracteriza por la utilización del conocimiento científico para el diseño de soluciones prácticas (Hernández-Sampieri et al., 2022).

El estudio adopta un alcance tecnológico-evaluativo, en tanto evalúa el desempeño de la solución implementada sobre un corpus de audios judiciales reales, a partir de métricas técnicas como Word Error Rate (WER), Character Error Rate (CER), Real-Time Factor (RTF) y Mean Opinion Score (MOS).

3.2.2 Método de Investigación

El método adoptado es experimental de tipo pre-experimental, ya que se comparan los resultados obtenidos antes y después de la implementación del sistema, utilizando el mismo conjunto de audios judiciales como base. Se evalúa la precisión de las transcripciones manuales frente a las generadas automáticamente por el sistema, midiendo mejoras en tiempo y exactitud. Este enfoque es apropiado cuando no es posible contar con grupos de control, pero se busca obtener evidencia empírica del impacto de la intervención (Kerlinger y Lee, 2020).

En paralelo, el desarrollo del software sigue el método ágil bajo el marco Scrum, lo que permite gestionar iterativamente el ciclo de vida del sistema.

3.2.3 Diseño de Investigación

El diseño de investigación es experimental de un solo grupo, orientado a comparar la precisión y eficiencia del proceso de transcripción judicial antes y después de la implementación del sistema automatizado. Las métricas evaluadas incluyen WER, CER, MOS y latencia promedio, las cuales permiten cuantificar el desempeño del sistema en condiciones reales. Este diseño es ampliamente utilizado en estudios de adopción tecnológica (Creswell

y Creswell, 2018).

3.2.4 Enfoque de Investigación

El enfoque es cuantitativo de validación tecnológica, dado que los resultados se expresan mediante indicadores numéricos de desempeño del sistema. Las métricas se calculan utilizando métodos objetivos estandarizados en el campo del procesamiento de lenguaje natural (Garneau y Bolduc, 2024; Loakes, 2024). Complementariamente, se incluye un análisis descriptivo que contextualiza los resultados en el entorno judicial, permitiendo formular recomendaciones para su adopción institucional.

3.3 Corpus y Unidad de Análisis

El corpus está constituido por grabaciones de audiencias del Distrito Judicial de Cusco, obtenidas con autorización institucional y sujetas a las disposiciones de la Ley N.º 29733. Las grabaciones provienen de audiencias presenciales y virtuales de distintas especialidades: penal, laboral y familia. Cada grabación tiene una duración mínima de 20 minutos y cuenta con la participación de al menos dos interlocutores.

Las transcripciones de referencia (*ground truth*) son elaboradas por personal judicial capacitado, quienes transcriben fielmente el contenido de cada audiencia. Estas transcripciones sirven de base para calcular las métricas de evaluación del sistema. La unidad de análisis es el segmento de transcripción: fragmento de texto producido por el sistema para un hablante identificado, que se contrasta con el fragmento equivalente en la transcripción de referencia.

3.4 Población y Muestra

Para la evaluación del sistema se seleccionarán de manera intencional 30 audiencias del Distrito Judicial de Cusco, distribuidas entre las especialidades penal, laboral y familiar, con criterio de equilibrio entre casos de alta y baja complejidad acústica. El criterio de selección incluye audios con una duración mínima de 20 minutos y participación de al menos dos interlocutores, de modo que el sistema sea evaluado en condiciones representativas del entorno real. La muestra se considera suficiente para calcular las métricas de error y preci-

sión con resultados estadísticamente relevantes, conforme a lo utilizado en estudios similares (Garneau y Bolduc, 2024; Harrington, 2023).

3.5 Técnicas e Instrumentos de Recolección de Datos

La técnica principal es la observación directa no participante, registrando los audios de las audiencias seleccionadas y recopilando sus transcripciones manuales de referencia. Los instrumentos utilizados incluyen: grabadora digital para captura de audio en alta calidad, script en Python para el preprocesamiento y normalización de los archivos de audio, el sistema automatizado desarrollado con FastAPI y Deepgram para la generación de transcripciones automáticas, y fichas de registro para almacenar los resultados de WER, CER, RTF y tiempo de entrega de actas.

Adicionalmente, se aplicará una encuesta de satisfacción a los operadores judiciales que utilicen el sistema, usando una escala Likert de 5 puntos para medir la percepción de mejora en la celeridad procesal y la calidad de las transcripciones (MOS).

3.6 Presupuesto

3.6.1 Recursos de Software y Servicios en la Nube

Cuadro 3.1: Costos de software y servicios en la nube

Servicio / Herramienta	Modalidad	Costo estimado (S/.)
Deepgram Nova-2 API (plan de pago por uso)	Por consumo	100,00
Claude Sonnet API (Anthropic)	Por consumo	50,00
Servidor VPS KVM 2 de Hostinger	1 año	350,00
Dominio web	1 año	40,00
Total		540,00

3.6.2 Presupuesto Total

Cuadro 3.2: Presupuesto total de la investigación

Rubro	Total (S/.)
Software y servicios en la nube y dominio	540,00
Imprevistos (10 %)	54,00
TOTAL GENERAL	594,00

3.6.3 Cronograma de Actividades

Cuadro 3.3: Cronograma de actividades de la investigación

Actividad	Mes 1	Mes 2	Mes 3	Mes 4	Mes 5	Mes 6	Mes 7	Mes 8
Revisión bibliográfica y estado del arte	•	•						
Elaboración y aprobación del plan de tesis	•	•						
Gestión de permisos institucionales (corpus)		•	•					
Recopilación y anonimización del corpus judicial			•	•				
Elaboración de transcripciones de referencia			•	•				
Diseño de arquitectura del sistema		•	•					
Implementación del MVP (Etapa 1)				•	•			
Pruebas unitarias e integración del MVP					•	•		
Implementación de módulos avanzados (Etapa 2)					•	•		
Evaluación del sistema con el corpus (WER, CER, RTF)						•	•	
Aplicación de encuesta de satisfacción (MOS)							•	
Análisis de resultados y validación estadística							•	•
Redacción del informe final de tesis					•	•	•	•
Revisión del asesor y levantamiento de observaciones							•	•
Sustentación y defensa de la tesis								•

REFERENCIAS

- Ao, J., Wang, R., Zhou, L., Wei, Z., y Zhang, S. (2022). SpeechT5: Unified-modal encoder-decoder pre-training for spoken language processing. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 30, 1–12. <https://doi.org/10.18653/v1/2022.acl-long.393>
- Baltrušaitis, T., Ahuja, C., y Morency, L. P. (2019). Multimodal machine learning: A survey and taxonomy. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 41(2), 423–443. <https://doi.org/10.1109/TPAMI.2018.2798607>
- Baevski, A., Zhou, H., Mohamed, A., y Auli, M. (2020). wav2vec 2.0: A framework for self-supervised learning of speech representations. *Advances in Neural Information Processing Systems (NeurIPS)*, 33, 12449–12460. <https://doi.org/10.48550/arXiv.2006.11477>
- Bauer, M., Draghi, M., y otros. (2025). *Boosting efficiency and quality in EU public services* (Occasional Paper No. 04/2025). ECIPE. <https://www.econstor.eu/bitstream/10419/315166/1/1920054340.pdf>
- Bild, E., Redman, A., Newman, E. J., Muir, B. R., Tait, D., y Schwarz, N. (2021). Sound and credibility in the virtual court: Low audio quality leads to less favorable evaluations of witnesses and lower weighting of evidence. *Law and Human Behavior*, 45(5), 481–495. <https://doi.org/10.1037/lhb0000466>
- Cabrera Fernández, R. (2024). Automatización de procesos judiciales mediante inteligencia artificial: Implicancias para la celeridad procesal y la transparencia institucional. *Revista Peruana de Derecho y Tecnología*, 8(1), 45–61. <https://doi.org/10.20318/eunomia.2024.9006>
- Chaloupka, J., Palecek, J., y Cerva, P. (2021). Audio-visual broadcast transcription system using artificial neural networks. *IEEE International Workshop on Electronics, Con-*

trol, Measurement, Signals and their Application to Mechatronics (ECMSM), 1–6. <https://doi.org/10.1109/ECMSM51310.2021.9468830>

Comisión Económica para América Latina y el Caribe (CEPAL). (2025). *Latin American Artificial Intelligence Index (ILIA 2025)*. <https://www.cepal.org/en/pressreleases/latin-america-and-caribbean-accelerate-adoption-artificial-intelligence>

Creswell, J. W., y Creswell, J. D. (2018). *Research design: Qualitative, quantitative, and mixed methods approaches* (5.^a ed.). SAGE.

Didena, T. (2024). Legal transcription services and access to justice: A qualitative analysis of court record-keeping in the Southern Nations, Nationalities, and Peoples' Region of Ethiopia. *African Journal of Law and Society*, 16(1), 45–62. <https://doi.org/10.1177/13657127231217774>

Fette, I., y Melnikov, A. (2011). *The WebSocket protocol* (RFC 6455). Internet Engineering Task Force (IETF). <https://doi.org/10.17487/RFC6455>

Garneau, G., y Bolduc, P. (2024). The state of commercial automatic French legal speech recognition systems and their impact on court reporters. *Journal of Legal Technology Studies*, 12(1), 1–22. <https://arxiv.org/abs/2408.11940>

Gulati, A., Qin, J., Chiu, C.-C., Parmar, N., Zhang, Y., Yu, J., y Wu, Y. (2020). Conformer: Convolution-augmented transformer for speech recognition. *Proceedings of Interspeech 2020*, 5036–5040. <https://doi.org/10.21437/Interspeech.2020-3015>

Harrington, J. (2023). Incorporating automatic speech recognition methods into the transcription of police-suspect interviews: Factors affecting automatic performance. *Journal of Forensic Phonetics*, 5(2), 77–94. <https://doi.org/10.3389/fcomm.2023.1165233>

Hernández-Sampieri, R., Fernández Collado, C., y Baptista Lucio, P. (2022). *Metodología de la investigación* (7.^a ed.). McGraw-Hill.

Kasakowskij, M. (2025). Distributed architectures for real-time speech recognition: Applications in justice systems. *International Journal of Cloud Computing and AI Systems*, 14(1), 50–68. <https://doi.org/10.1007/s44217-025-00568-6>

- Kerlinger, F. N., y Lee, H. B. (2020). *Foundations of behavioral research* (5.^a ed.). Cengage.
- Koenecke, A., Nam, A., Lake, E., Nudell, J., Quartey, M., Mengesha, Z., y Goel, S. (2020). Racial disparities in automated speech recognition. *Proceedings of the National Academy of Sciences*, 117(14), 7684–7689. <https://doi.org/10.1073/pnas.1915768117>
- Larrea, P. (2024). *Uso de la plataforma Google Meet y transcriptor IA en el proceso de trámite de las audiencias del módulo penal dentro del Poder Judicial de Junín en la sub sede central Huancayo 2024* [Tesis de maestría, Universidad Nacional del Centro del Perú]. <https://repositorio.uncp.edu.pe/handle/20.500.12894/12608>
- Latif, S., Qureshi, S. A., Maqsood, M., y Ali, H. (2023). A survey of transformers in speech processing: Architectures, applications and challenges. *IEEE Access*, 11, 12953–12974. <https://doi.org/10.1109/ACCESS.2023.3241234>
- Legchenko, A., y Bondarenko, I. (2025). *Adopting domain-specific knowledge in ASR systems*. Proceedings of the MathAI 2025 Conference. Novosibirsk State University. <https://openreview.net/pdf?id=dzrEXinn4N>
- Loakes, D. (2024). Automatic speech recognition and the transcription of indistinct forensic audio: How do the new generation of systems fare? *Frontiers in Communication*, 9, 1–12. <https://www.frontiersin.org/journals/communication/articles/10.3389/fcomm.2024.1281407/full>
- Lyra, A., Barbosa, C. E., Salazar, H., Argôlo, M., Lima, Y., Motta, R., y Moreira de Souza, J. (2024). Automatic transcription systems: A game changer for court hearings. En *Proceedings of the 16th International Joint Conference on Knowledge Discovery, Knowledge Engineering and Knowledge Management* (pp. 163–174). SCITEPRESS. <https://doi.org/10.5220/0012891400003838>
- Macháček, J., Švec, J., y Žmolík, M. (2023). Low-latency automatic speech recognition systems for real-time applications: A performance evaluation. *Journal of Real-Time Image Processing*, 20(3), 421–435. <https://doi.org/10.3389/frsip.2022.999457>
- Morris, A., Maier, V., y Green, P. (2004). From WER and RIL to MER and WIL: Improved evaluation measures for connected speech recognition. *IEEE Signal Processing Letters*,

12(10), 1–4.

Nascimento, F., Silva, R., y Duarte, L. (2024). Automated transcription in parliamentary sessions: Efficiency gains and legal considerations. *Parliamentary Technology Review*, 22(3), 88–105. <https://doi.org/10.1177/ptr.2024.88>

OCDE. (2023). *Principios de la OCDE sobre la inteligencia artificial*. Organización para la Cooperación y el Desarrollo Económicos. <https://oecd.ai>

Poder Judicial del Perú. (2023). *Reglamento de audiencias virtuales y uso de medios tecnológicos en procesos judiciales*. Consejo Ejecutivo del Poder Judicial.

Prescott, J. J. (2020). Improving access to justice in state courts with platform technology. *Vanderbilt Law Review*, 73(6), 1875–1928. <https://scholarship.law.vanderbilt.edu/vlr/vol73/iss6/6>

Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., y Sutskever, I. (2022). Robust speech recognition via large-scale weak supervision. *arXiv preprint arXiv:2212.04356*. <https://doi.org/10.48550/arXiv.2212.04356>

Radford, A., Kim, J. W., Xu, T., Brockman, G., y Amodei, D. (2023). *Robust speech recognition via large-scale weak supervision*. OpenAI. <https://cdn.openai.com/papers/whisper.pdf>

Rubio Portilla, J. (2023). Audiencias virtuales y su impacto en el debido proceso penal en un distrito judicial. *SCIÉENDO*, 26(4), 204–214. <https://doi.org/10.17268/sciendo.2023.057>

Russell, S. J., y Norvig, P. (2024). *Inteligencia artificial: Un enfoque moderno* (4.^a ed.). Pearson Educación.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., y Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems (NeurIPS)*, 30, 5998–6008. <https://doi.org/10.48550/arXiv.1706.03762>

Vera, L. (2021). STT: Un sistema de apoyo a la transcripción de audiencias fiscales usando Vosk. *Revista de Investigación de Sistemas e Informática*, 24(1), 45–57. <https://doi.org/10.1177/01875968211011111>

org/10.15381/risi.v14i1.21864

Yépez-Reyes, M., y Cruz-Silva, A. (2024). Inteligencia artificial en la transcripción de entrevistas: Comparativa de herramientas y métricas de calidad. *Contratexto*, (41). <https://doi.org/10.26439/contratexto2024.n41.6750>

Zuchowski, M., y Göller, S. (2022). Voice recognition in medical documentation: A time-motion study comparing dictation and keyboard entry in clinical practice. *Applied Clinical Informatics*, 13(2), 410–418. <https://doi.org/10.1055/s-0042-1748144>